# Trabajo Final: Aplicaciones de Inteligencia de Datos

**Maestría en Ciencia de Datos - Universidad Nacional Arturo Jauretche**

Raúl Burgos, Mauro Cejas Marcovecchio, Raúl Muñóz, Mirta Soto

## Contenido

**1 Descripción** **2**

**2 EDA y Preprocesamiento** **2**
Preprocesamiento básico y limpieza inicial . . . . . 2
Preprocesamiento y limpieza avanzada de datos . . . . . 12

**3 Modelado, Evaluación e Interpretabilidad** **13**
Selección de modelos . . . . . 13
Entrenamiento, validación y optimización de modelos . . . . . 14
Evaluación y análisis de resultados . . . . . 15
Interpretabilidad de los modelos . . . . . 17
Conclusiones . . . . . 18

**Referencias** **19**

# 1. Descripción

El presente trabajo tiene como objetivo el análisis exploratorio, el procesamiento de datos y el desarrollo de modelos de aprendizaje automático (*machine learning*) para la predicción de la radiación solar global. Los datos empleados fueron obtenidos del Sistema de Información y Gestión Agrometeorológica (SIGA), dependiente del Instituto Nacional de Tecnología Agropecuaria (INTA) e incluyen registros de tres estaciones meteorológicas localizadas en las localidades de Goya, Bella Vista y Herliszka, en la provincia de Corrientes, Argentina.

El repositorio completo del proyecto se encuentra disponible en el enlace: https://github.com/cejasmau/tp_aplicaciones

La provincia de Corrientes presenta un clima clasificado, según el sistema de Köppen, como subtropical sin estación seca, con predominancia de clima subtropical húmedo en su sector noreste. Según el último informe agroclimático anual de Bella Vista publicado por el INTA en 2020, la temperatura media mensual registró valores entre 14,8 °C y 26,9 °C. Las precipitaciones son abundantes en la región, con un promedio histórico anual de 1.258,5 mm; aún así, durante el período analizado se registró una reducción considerable, alcanzando los 794,7 mm anuales. Los periodos lluviosos se dan especialmente en los equinoccios de otoño y primavera, siendo el invierno y el verano las estaciones más secas del año. Los veranos se caracterizan por temperaturas elevadas, con máximas que en 2020 alcanzaron los 40 °C y alta humedad relativa. Los inviernos, en cambio, presentan condiciones templado-frías. Los vientos que más afectan a la provincia son el norte muy cálido proveniente de Brasil, el pampero frío y seco proveniente de la Patagonia y la sudestada frío y húmedo proveniente del mar argentino.

# 2. EDA y Preprocesamiento

## Preprocesamiento básico y limpieza inicial

El punto de partida del trabajo corresponde a los tres conjuntos de datos independientes, provenientes de cada estación meteorológica, los cuales presentan una estructura idéntica de 30 variables. Con el fin de consolidar la información disponible, se incorporó una variable identificadora de la localidad de origen y se procedió a la unificación de los tres conjuntos en una única base de datos.

Dado que las estaciones se encuentran ubicadas a distancias geográficas relativamente próximas entre sí y presentan altitudes similares, con valores comprendidos entre los 57 y 66 metros sobre el nivel del mar, se consideró que estas características no constituían factores diferenciadores significativos respecto a la radiación global, la variable objetivo del trabajo. Por este motivo, la localización geográfica y la altitud no fueron incorporadas como variables predictoras en el análisis.

```
Dimensiones del dataset de Goya: (3939, 30)
Dimensiones del dataset de Bella Vista: (3714, 30)
Dimensiones del dataset de Herlitzka: (2220, 30)
```

### Cantidad de registros, variables y tipos

De este modo, el conjunto de datos resultante comprende un total de 9.873 registros y 31 variables. Sin embargo, a lo largo del precente trabajo se procedió a descartar aquellas variables que no reunían condiciones suficientes de calidad, cantidad o representatividad para integrar el conjunto de variables explicativas.

En ese sentido, se identificó que las variables asociadas a la medición de temperatura a la intemperie y a la temperatura del suelo a 5 cm de profundidad carecían de valores válidos, situación que se extendió también a la variable de humedad del suelo. Dado que su inclusión no aportaría información útil al modelo, estas variables fueron excluidas del análisis.

Asimismo, las variables vinculadas a la heliofanía fueron descartadas, debido a que este fenómeno se encuentra intrínsecamente asociado a la variable objetivo. Su incorporación como variable predictora no permitiría la identificación de factores subyacentes que la expliquen, sino que produciría modelos con una capacidad predictiva casi perfecta pero carentes de utilidad analítica.

Por último, se excluyeron las variables correspondientes a las temperaturas mínimas a la intemperie a 50 y 150 cm de altura, dado que ambas presentaban aproximadamente un 85 % de valores faltantes, proporción que las hace inviables para su uso en el análisis.

Así, tal como se observa en el Gráfico 1, el conjunto de datos está compuesto por variables de tres tipos: categóricas (dirección del viento y nombre de la localidad), temporales (fecha) y numéricas (el resto de las variables).

| Variables | Expresada en (unidades) | Tipo | Valores no nulos | Valores faltantes |
|---|---|---|---|---|
| Fecha | - | Fecha/Hora | 9873 | 0 |
| Temperatura_Abrigo_150cm | °C | Numérico | 9508 | 365 |
| Temperatura_Abrigo_150cm_Maxima | °C | Numérico | 9493 | 380 |
| Temperatura_Abrigo_150cm_Minima | °C | Numérico | 9487 | 386 |
| Temperatura_Intemperie_5cm_Minima | °C | NA | 0 | 9873 |
| Temperatura_Intemperie_50cm_Minima | °C | Numérico | 1404 | 8469 |
| Temperatura_Suelo_5cm_Media | °C | NA | 0 | 9873 |
| Temperatura_Suelo_10cm_Media | °C | Numérico | 9116 | 757 |
| Temperatura_Inte_5cm | °C | NA | 0 | 9873 |
| Temperatura_Intemperie_150cm_Minima | °C | Numérico | 1412 | 8461 |
| Humedad_Suelo | % | NA | 0 | 9873 |
| Precipitacion_Pluviometrica | mm | Numérico | 9149 | 724 |
| Precipitacion_Cronologica | mm | Numérico | 9129 | 744 |
| Precipitacion_Maxima_30minutos | mm | Numérico | 8324 | 1549 |
| Heliofania_Efectiva | h | Numérico | 7942 | 1931 |
| Heliofania_Relativa | % | Numérico | 7939 | 1934 |
| Tesion_Vapor_Media | hPa | Numérico | 9437 | 436 |
| Humedad_Media | % | Numérico | 9502 | 371 |
| Humedad_Media_8_14_20 | % | Numérico | 9475 | 398 |
| Rocio_Medio | °C | Numérico | 8754 | 1119 |
| Duracion_Follaje_Mojado | h | Numérico | 9041 | 832 |
| Velocidad_Viento_200cm_Media | km/h | Numérico | 8998 | 875 |
| Direccion_Viento_200cm | - | Texto | 9566 | 307 |
| Velocidad_Viento_1000cm_Media | km/h | Numérico | 8998 | 875 |
| Direccion_Viento_1000cm | - | Texto | 9566 | 307 |
| Velocidad_Viento_Maxima | km/h | Numérico | 9049 | 824 |
| Presion_Media | Pa | Numérico | 9041 | 832 |
| Radiacion_Global | MJ/m2 | Numérico | 9041 | 832 |
| Horas_Frio | h | Numérico | 9426 | 447 |
| Unidades_Frio | - | Numérico | 9427 | 446 |
| Localidad | - | Texto | 9873 | 0 |

Gráfico 1: Resumen exploratorio de variables del dataset.

### Valores faltantes, duplicados e inconsistencias

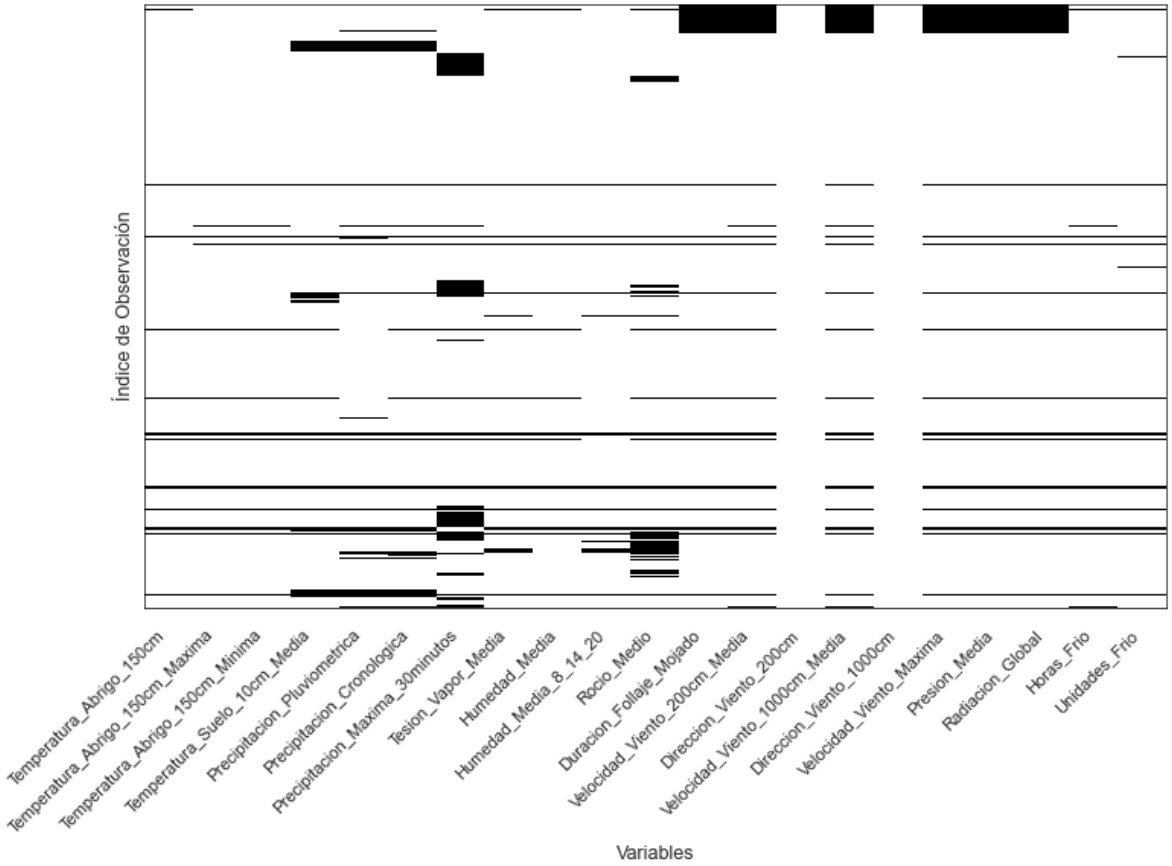


Gráfico 2: Mapa de valores faltantes en el conjunto de datos

Como se observa en el Gráfico 2, se identificaron múltiples registros en los que todos los campos presentaban valores faltantes, a excepción de las variables correspondientes a la dirección del viento y la fecha. Dichos registros fueron identificados y eliminados del conjunto de datos.

Asimismo, se verificó que la variable objetivo del trabajo presenta una cantidad considerable de valores faltantes, concentrados principalmente en los registros iniciales del dataset. Dado que esta variable constituye el objeto de predicción del estudio, los registros en los que adopta valores nulos fueron descartados del análisis.

Finalmente, las variables asociadas a la dirección y velocidad del viento fueron excluidas del conjunto de variables explicativas. Además de exhibir una relación indirecta y de baja magnitud con la radiación solar, presentan una proporción considerable de valores nulos e inconsistencias en su registro, factores que comprometen su utilidad como predictores.

### Resumen estadístico

| Variables | min | X25. | X50. | mean | X75. | max | IQR | Moda | std |
|---|---|---|---|---|---|---|---|---|---|
| Temperatura_Abrigo_150cm | 3.41 | 17.32 | 21.97 | 21.29 | 25.57 | 42.96 | 8.25 | 24.91 | 5.63 |
| Temperatura_Abrigo_150cm_Maxima | 9.50 | 23.60 | 28.50 | 27.97 | 32.70 | 60.00 | 9.10 | 29.70 | 6.38 |
| Temperatura_Abrigo_150cm_Minima | −28.10 | 12.10 | 16.70 | 15.91 | 20.30 | 43.30 | 8.20 | 19.80 | 5.77 |
| Temperatura_Suelo_10cm_Media | −6.80 | 19.12 | 23.94 | 23.70 | 27.90 | 50.00 | 8.78 | 27.58 | 5.89 |
| Precipitacion_Pluviometrica | 0.00 | 0.00 | 0.00 | 3.16 | 0.20 | 169.00 | 0.20 | 0.00 | 11.49 |
| Precipitacion_Cronologica | 0.00 | 0.00 | 0.00 | 3.17 | 0.00 | 220.00 | 0.00 | 0.00 | 11.94 |
| Precipitacion_Maxima_30minutos | 0.00 | 0.00 | 0.00 | 1.25 | 0.00 | 58.20 | 0.00 | 0.00 | 4.47 |
| Tesion_Vapor_Media | 0.01 | 14.41 | 19.22 | 19.45 | 24.27 | 73.20 | 9.86 | 11.67 | 6.90 |
| Humedad_Media | 0.00 | 65.00 | 77.00 | 74.63 | 87.00 | 100.00 | 22.00 | 100.00 | 17.65 |
| Humedad_Media_8_14_20 | 3.00 | 62.00 | 75.00 | 73.26 | 86.00 | 100.00 | 24.00 | 100.00 | 17.23 |
| Rocio_Medio | −7.96 | 12.83 | 17.07 | 16.49 | 20.72 | 34.39 | 7.89 | 10.56 | 5.62 |
| Duracion_Follaje_Mojado | 0.00 | 0.00 | 1.08 | 3.57 | 6.77 | 24.00 | 6.77 | 0.00 | 4.58 |
| Presion_Media | 986.28 | 1,000.38 | 1,004.11 | 1,004.73 | 1,008.71 | 1,033.71 | 8.33 | 1,004.44 | 6.12 |
| Radiacion_Global | 0.02 | 9.59 | 15.17 | 15.51 | 22.14 | 32.27 | 12.55 | 4.24 | 7.86 |
| Horas_Frio | 0.00 | 0.00 | 0.00 | 0.54 | 0.00 | 18.92 | 0.00 | 0.00 | 2.09 |
| Unidades_Frio | −23.90 | −23.90 | −21.33 | −15.87 | −10.54 | 19.51 | 13.36 | −23.90 | 10.70 |

Gráfico 3: Resumen de estadísticas descriptivas de las variables.

## Visualizaciones y limpieza avanzada de datos

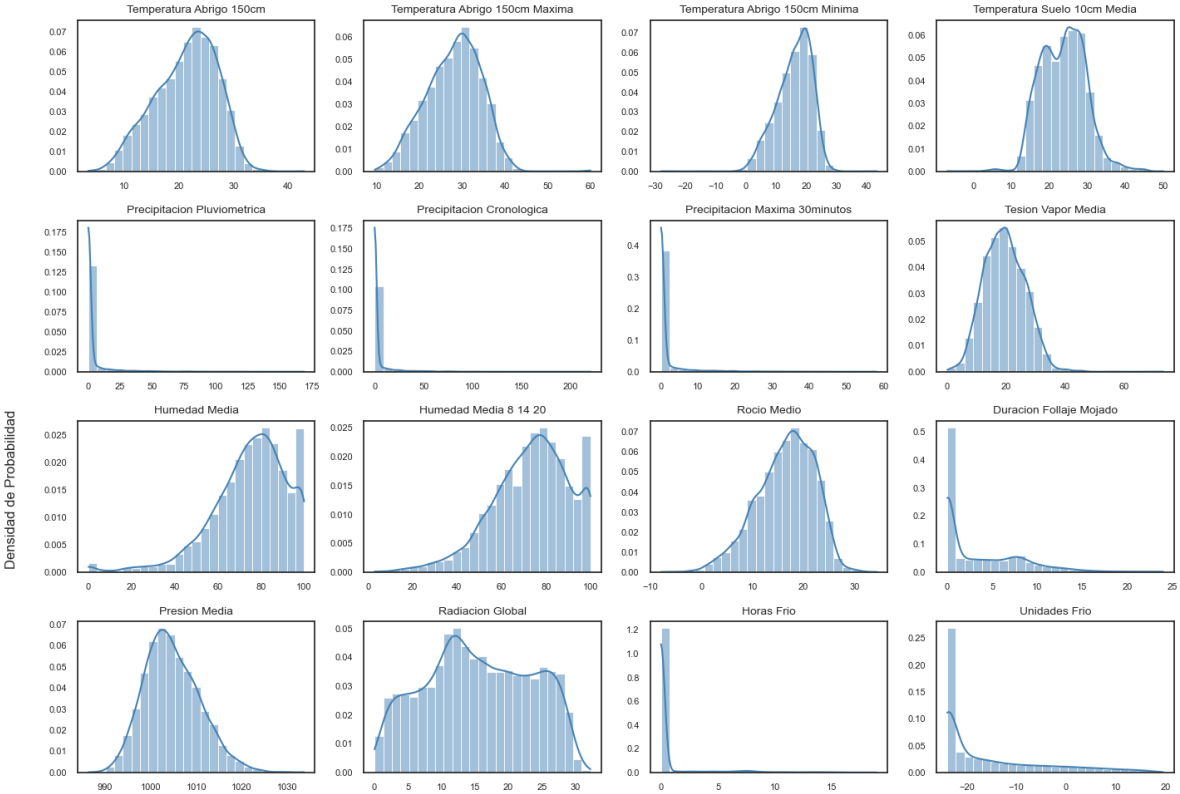


Gráfico 4: Distribución de frecuencias y densidad de probabilidad de las variables

A partir de los gráficos de distribución de frecuencias (Gráfico 4), se observa que las variables vinculadas a la temperatura, la radiación global, tesión de vapor, rocío medio y presión media presentan distribuciones aproximadamente simétricas. Las variables asociadas a la humedad, en cambio, exhiben un sesgo positivo. Por su parte, las precipitaciones, la duración del follaje mojado y las horas y unidades de frío presentan distribuciones que se aproximan a una distribución gamma, alejándose de la normalidad.

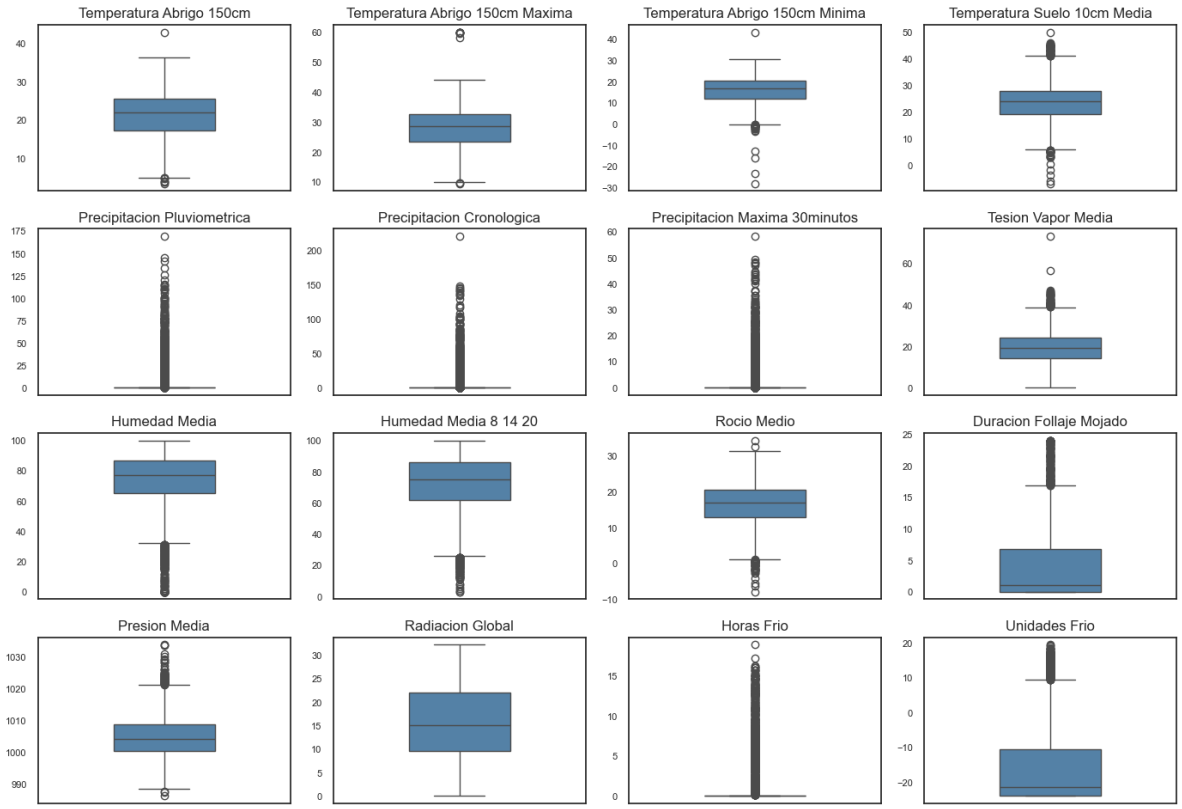


Gráfico 5: Diagramas de cajas y bigotes

En segundo lugar, el análisis de los diagramas de caja y bigotes revela que la mayoría de las variables presentan *outliers*, es decir, observaciones que se desvían considerablemente de los límites definidos por los percentiles 25 y 75 (inferior y superior). Las excepciones son la radiación global y, en menor medida, las variables de temperatura de abrigo, que exhiben una dispersión más contenida. Las variables asociadas a las precipitaciones y las horas de frío son las que concentran la mayor presencia de valores extremos.

Dado que la presencia de valores atípicos puede afectar medidas estadísticas como la media y la desviación estándar, distorsionar la representación gráfica de los datos y reducir el rendimiento de los modelos de aprendizaje automático, en etapas posteriores del análisis se procederá a su identificación para determinar, en cada caso, si corresponde su transformación o eliminación del conjunto de datos.

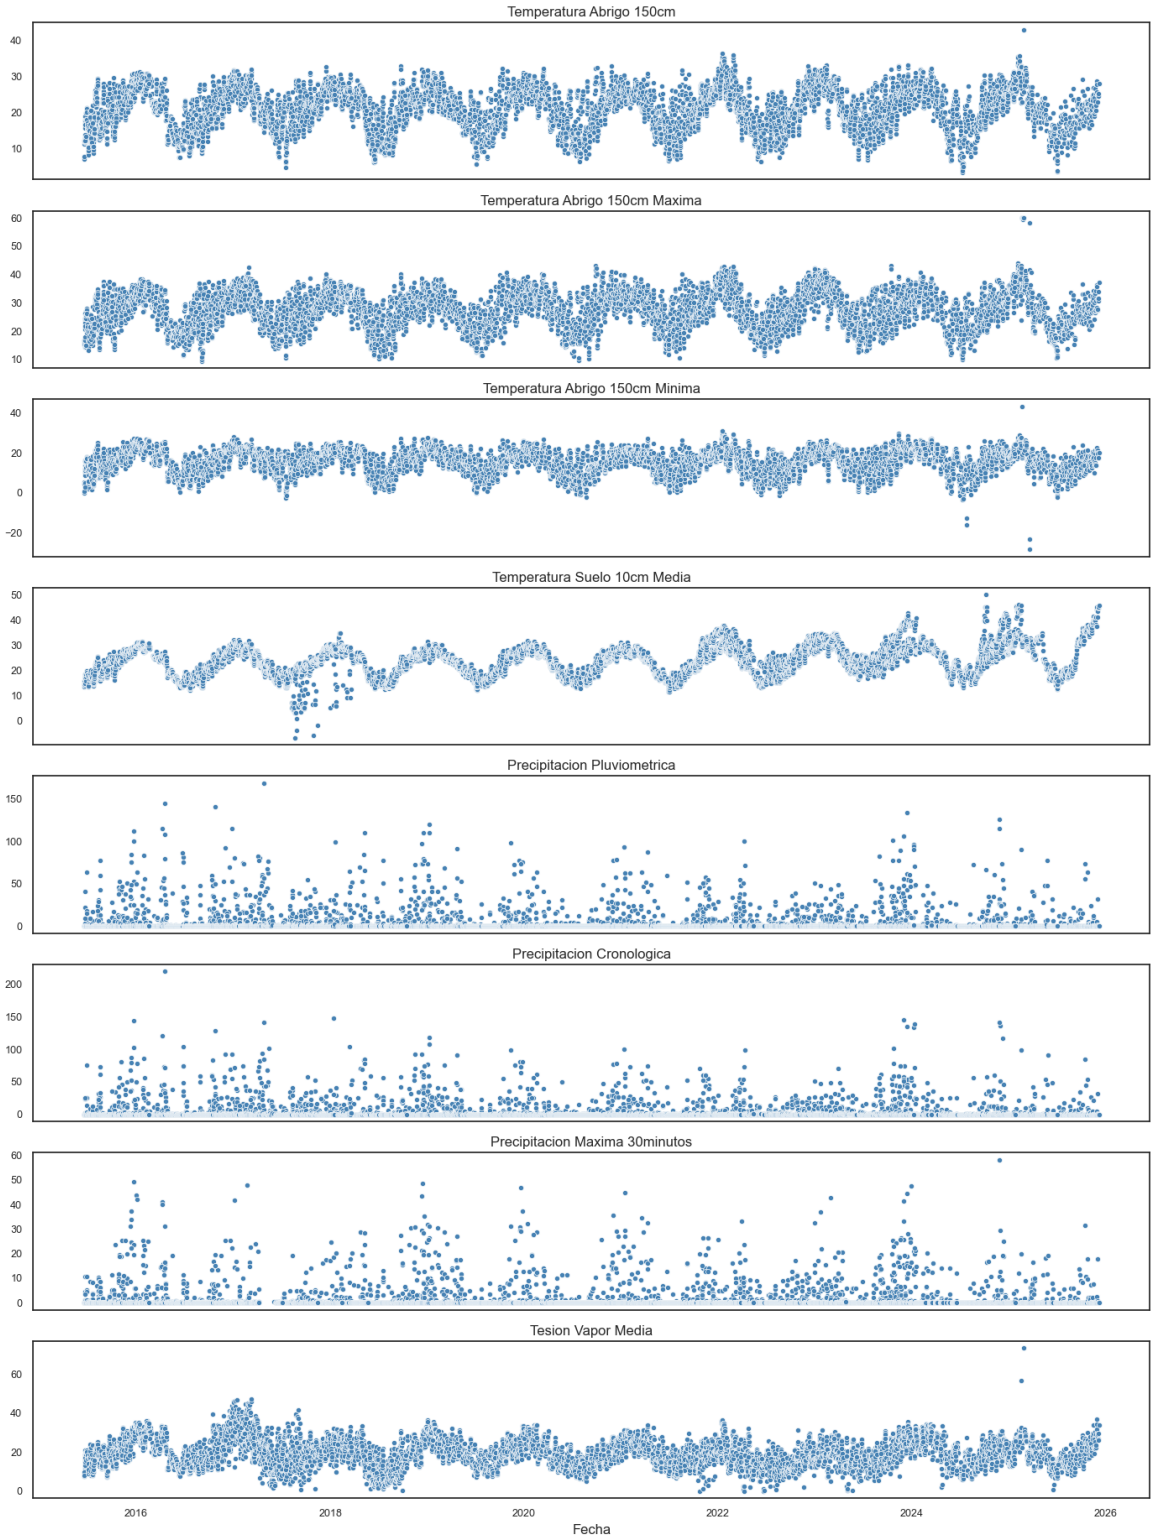


Gráfico 6: Series temporales de las variables estudiadas (I)

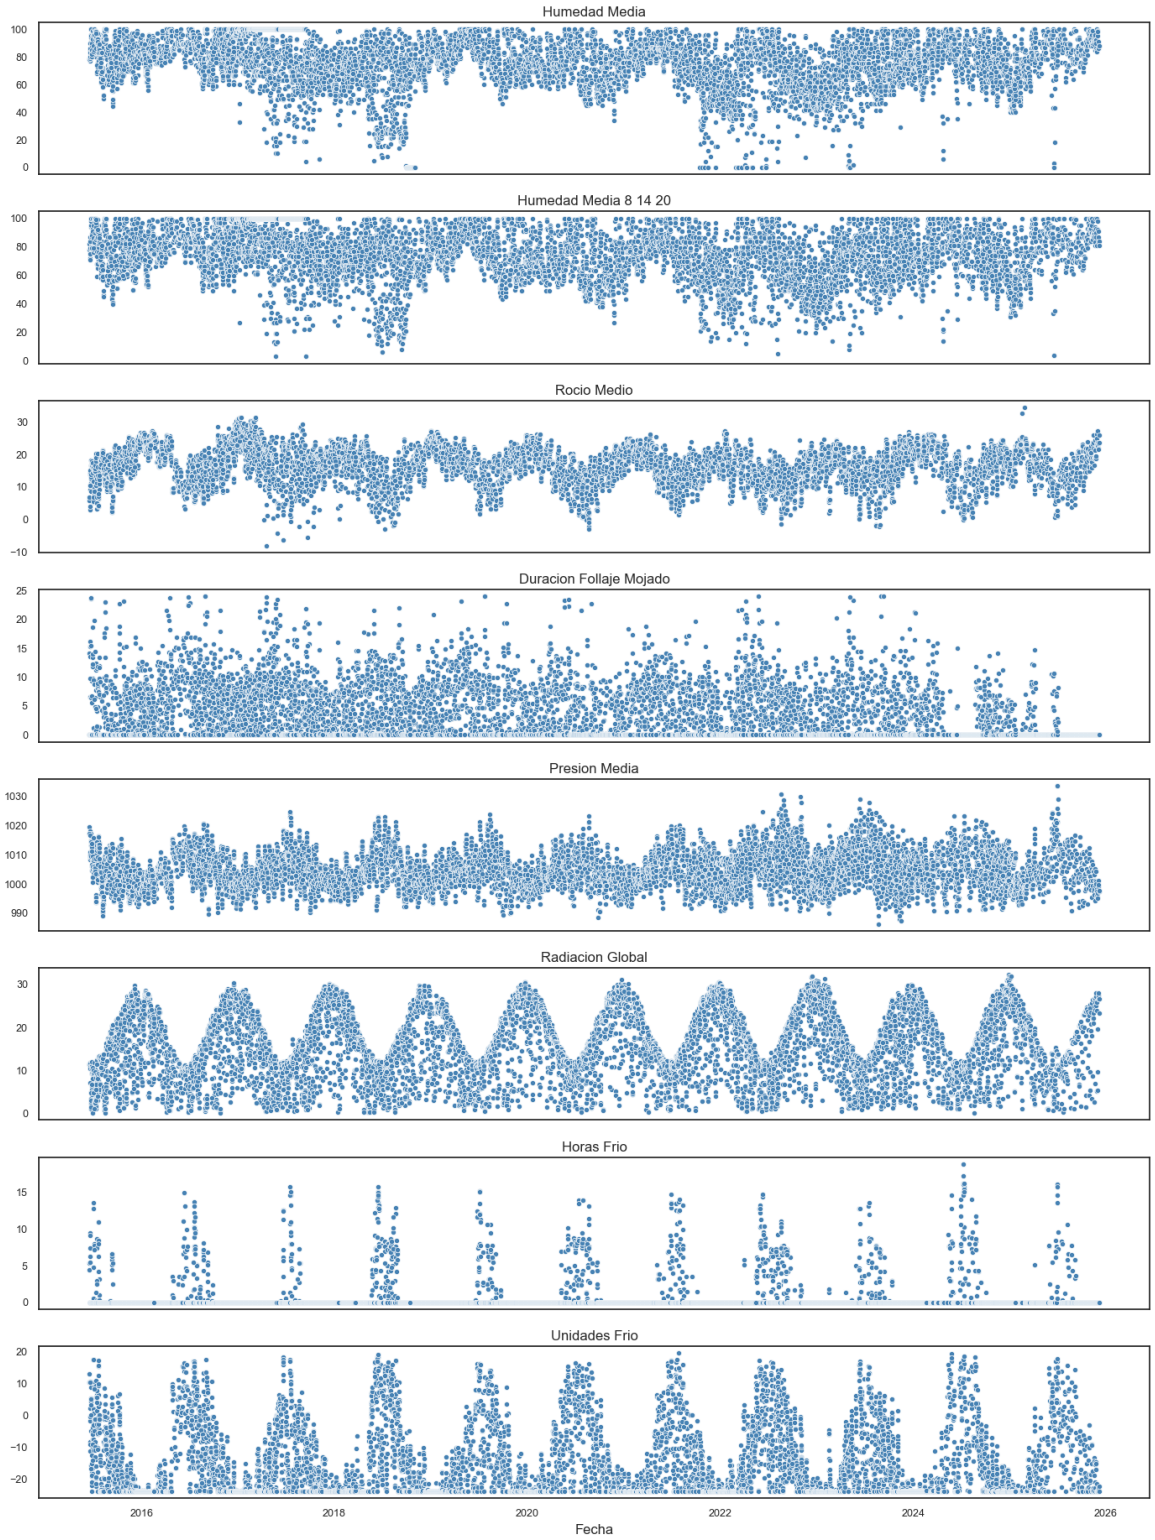


Gráfico 7: Series temporales de las variables estudiadas (II)

En tercer lugar, los gráficos de dispersión (Gráficos 6 y 7) permiten identificar con claridad un componente estacional en los datos.Dado que los meses presentan una naturaleza cíclica, su incorporación como variable numérica lineal no permitiría capturar adecuadamente los patrones estacionales. Para preservar esta continuidad, se aplicó una transformación cíclica que proyecta los meses sobre un círculo unitario, de modo que la distancia entre meses consecutivos (incluyendo la transición de diciembre a enero) sea uniforme y matemáticamente coherente.

$$mes_sin = \sin\left(\frac{2\pi \cdot mes}{12}\right), \quad mes_cos = \cos\left(\frac{2\pi \cdot mes}{12}\right)$$

Si bien esta transformación genera dos componentes (seno y coseno), el coseno tiende a presentar una mayor correlación con variables que alcanzan sus valores extremos en invierno o verano, lo que sugiere que este componente capturará de manera más efectiva la relación con la variable objetivo.

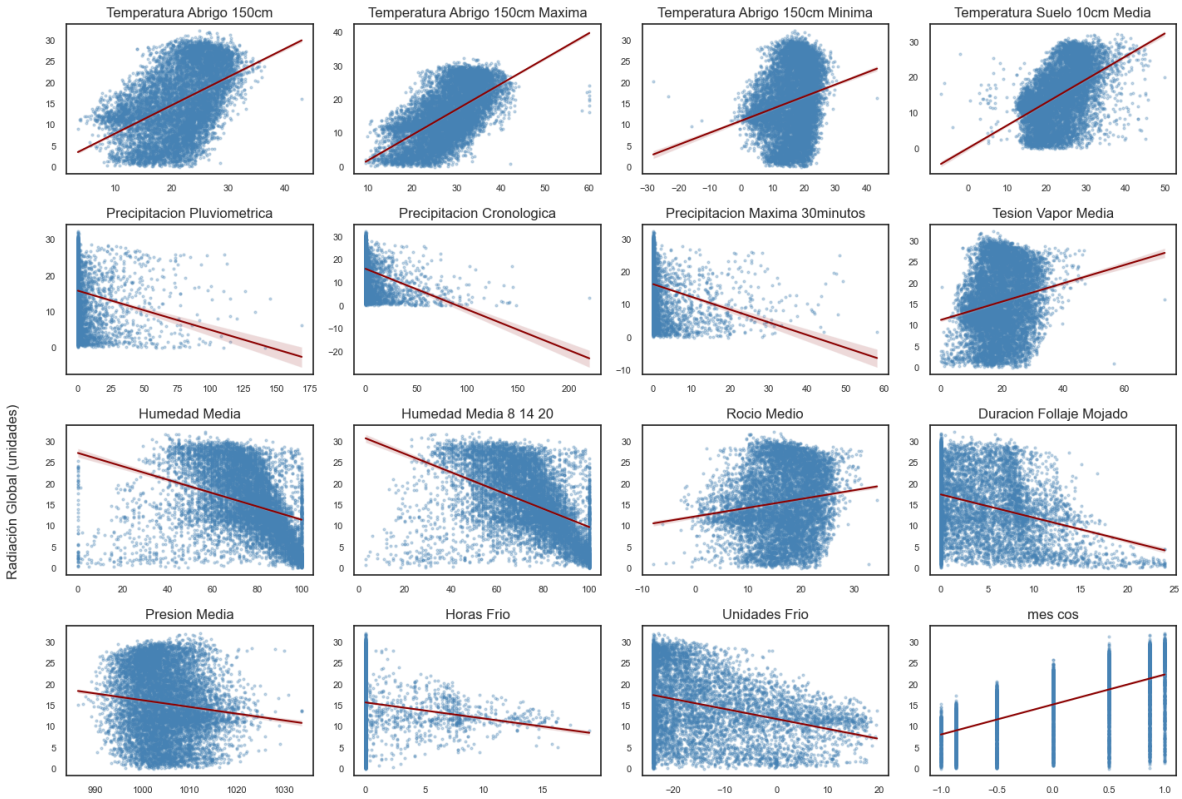


Gráfico 8: Relación entre la radiación global y las variables estudiadas

Por último, el análisis de los gráficos de dispersión entre la radiación global y el resto de las variables (Gráfico 8), junto con la matriz de correlación (Gráfico 9), permite identificar que

algunas de ellas presentan coeficientes de correlación de Pearson estadísticamente significativos, tanto con la variable objetivo como entre sí. Este último aspecto resulta relevante, dado que la presencia de multicolinealidad entre las variables predictoras puede comprometer la interpretación y el rendimiento de determinados modelos.

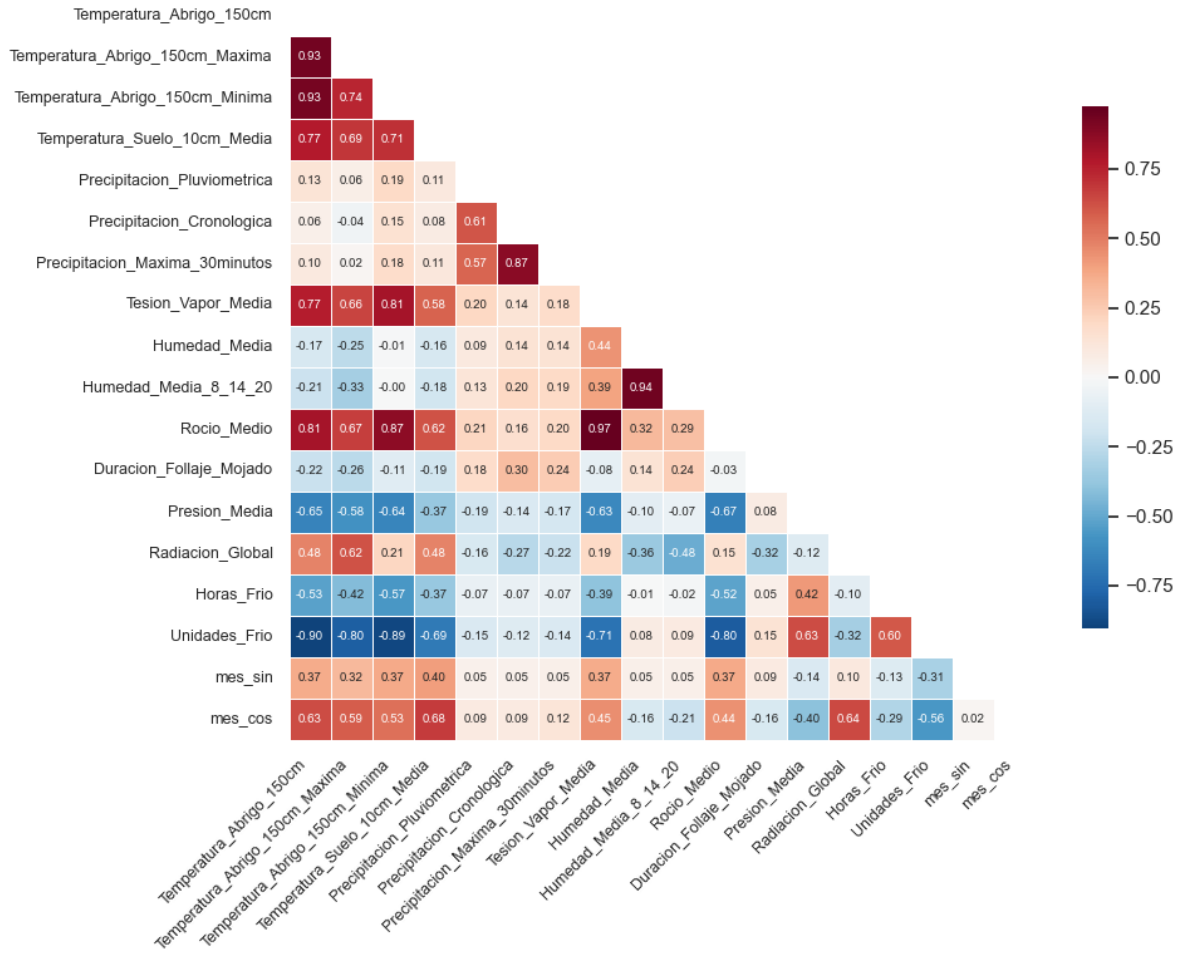


Gráfico 9: Matriz de correlación de Pearson para las variables estudiadas

## Preprocesamiento y limpieza avanzada de datos

Con el fin de establecer una estrategia para el tratamiento de valores atípicos, las variables fueron agrupadas en dos categorías según su distribución. Para aquellas con una distribución similar a la normal, se aplicó un límite superior fijado en tres desviaciones estándar respecto a la media, con el propósito de mitigar el impacto de los valores extremos. Para las variables con una distribución asimilable a la gamma, caracterizadas por una marcada asimetría positiva,

se optó por un criterio basado en percentiles, estableciendo el límite superior en el percentil 99,5.

El tratamiento de valores faltantes se llevó a cabo en dos etapas, diferenciando el método de imputación según la cantidad de días consecutivos sin registro. Se estableció un umbral de tres días como criterio de separación. Para períodos de hasta tres días, se aplicó interpolación lineal de forma independiente para cada estación meteorológica.

Para períodos superiores a tres días, se empleó el algoritmo *K-Nearest Neighbors* (KNN), que imputa cada valor faltante como una combinación ponderada de los k vecinos más similares en el espacio multivariado, aprovechando la correlación espacial y temporal entre las variables con las que disponemos. Previamente a su aplicación, las variables fueron estandarizadas mediante *z-score*, transformación necesaria para garantizar el correcto funcionamiento del algoritmo KNN: sin estandarización, las variables de mayor magnitud o varianza dominarían el cálculo de distancias, introduciendo un sesgo sistemático en la selección de vecinos. Una vez completada la imputación, los valores fueron reescalados a su escala original mediante la transformación inversa.

Finalmente, dado que los modelos de aprendizaje automático requieren valores numéricos, la variable categórica correspondiente a la localidad fue transformada mediante el método de codificación *One-Hot Encoding*. Este enfoque resulta especialmente adecuado para modelos de regresión, algoritmos de aprendizaje supervisado como las máquinas de vectores de soporte (SVM) y redes neuronales, ya que evita la introducción de un orden artificial entre las categorías.

# 3. Modelado, Evaluación e Interpretabilidad

## Selección de modelos

Se seleccionaron los modelos Random Forest y XG Boost debido a su capacidad para modelar interacciones complejas entre variables climáticas. Por un lado Random Forest ofrece una base estable y fácil de interpretar, captura de no linealidad, robustez frente a los outliers e importancia de las variables (permite cuantificar cuanto aporta cada variable a la predicción). Mientras que el XGboost permite maximizar la precisión predictiva mediante el ajuste de hiperparámetros. Este modelo entrena los árboles de forma secuencial, donde cada nuevo árbol aprende de los errores del anterior. Podemos destacar su alta precisión, manejo de datos faltantes y regularización (incluye técnicas de sobreajuste).

Las variables predictoras fueron seleccionadas principalmente a partir del análisis de los gráficos 8 y 9, que describen la relación entre la radiación global y las variables estudiadas, y la matriz de correlación, respectivamente. Fueron incorporadas aquellas que presentaron coeficientes estadísticamente significativos con la variable objetivo y no mostraron grados significativos de correlación con las demás variables predictoras: temperatura máxima bajo abrigo a 150

cm, humedad media en los horarios de observación (8, 14, 20), unidades de frío acumuladas, duración del follaje mojado, componente cíclica del mes (mes_cos), temperatura media del suelo a 10 cm y precipitación cronológica.

### Entrenamiento, validación y optimización de modelos

Para la prueba inicial de los modelos, se adoptó un esquema de validación *Hold-out*, mediante el cual el conjunto de datos se particionó en dos subconjuntos: un conjunto de entrenamiento, correspondiente al 80 % de las observaciones, y un conjunto de prueba, conformado por el 20 % restante. El subconjunto de entrenamiento fue utilizado para ajustar los parámetros de cada modelo a partir de las relaciones existentes entre las variables climáticas predictoras y la radiación solar. El subconjunto de prueba, por su parte, se reservó exclusivamente para la evaluación final del rendimiento, garantizando que las métricas obtenidas reflejen la capacidad de generalización de los modelos ante datos no observados durante el entrenamiento. Con el fin de asegurar la reproducibilidad de los experimentos, la partición se realizó fijando una semilla de aleatoriedad (random_state=42).

Además, el desempeño de los modelos fue cuantificado mediante dos métricas complementarias. En primer lugar, el coeficiente de determinación ($R^2$), que expresa la proporción de la varianza de la variable objetivo explicada por el modelo. En segundo lugar, el error absoluto medio (MAE), que indica el promedio de las diferencias absolutas entre los valores observados y los predichos, es decir, cuántas unidades de radiación se equivoca el modelo en cada predicción.

```
--- Resultados Random Forest ---
R2 Score: 0.8309
MAE: 2.38

--- Resultados XGBoost ---
R2 Score: 0.8404
MAE: 2.31
```

La optimización de hiperparámetros se llevó a cabo mediante *RandomizedSearchCV*, que a diferencia de la búsqueda exhaustiva (*Grid Search*) explora muestras aleatorias del espacio de hiperparámetros, ofreciendo una reducción sustancial del costo computacional sin sacrificar significativamente la calidad de la solución encontrada. Como esquema de validación interna se empleó una validación cruzada de $k = 5$ pliegues (*5-Fold Cross-Validation*), en la que el conjunto de entrenamiento se dividió en cinco subconjuntos de igual tamaño. En cada iteración, el modelo fue entrenado sobre cuatro subconjuntos y evaluado sobre el restante, rotando sistemáticamente hasta que cada subconjunto actuó una vez como conjunto de validación. Este procedimiento reduce la dependencia del rendimiento estimado respecto de una partición arbitraria de los datos y favorece la generalización de los resultados a distintos períodos temporales.

Su objetivo se centró en equilibrar la capacidad de aprendizaje con la generalización. Para ambos algoritmos, se ajustó la cantidad de estimadores/árboles (*n_estimators*) y la profundidad máxima (*max_depth*), permitiendo configuraciones de crecimiento libre para capturar interacciones complejas en los datos. En el caso de RF, la robustez se reforzó mediante restricciones en la división de nodos (*min_samples_split* y *leaf*) y el uso de técnicas de *bootstrap*, comparando la construcción de árboles mediante re-muestreo con reemplazo frente al uso del conjunto de datos completo para optimizar la estabilidad de las predicciones. Por su parte, XGBoost incorporó un control del tamaño del paso en cada iteración del proceso de boosting mediante *learning_rate* y el parámetro *gamma*, el cual actúa como un umbral de reducción mínima de pérdida para habilitar nuevas particiones. La reducción del sobreajuste en ambos modelos se garantizó mediante mecanismos de aleatoriedad: submuestreo de variables (*max_features*/*colsample_bytree*) y observaciones (*subsample*), además de la aplicación de regularización *L1* y *L2* en el caso de XGBoost, que penalizan la complejidad de los pesos en las hojas del modelo.

```
Mejor R2 RF: 0.8229

Mejores hiperparámetros:
  n_estimators: 500
  min_samples_split: 2
  min_samples_leaf: 2
  max_features: sqrt
  max_depth: None
  bootstrap: True

Mejor R2 XGB: 0.8278

Mejores hiperparámetros:
  subsample: 0.8
  reg_lambda: 1.5
  reg_alpha: 0.01
  n_estimators: 200
  max_depth: 6
  learning_rate: 0.05
  gamma: 0
  colsample_bytree: 0.6
```

## Evaluación y análisis de resultados

Con el objetivo de evaluar y contrastar el desempeño de los modelos (Random Forest y XGBoost) se seleccionó un conjunto de métricas de regresión. Dada la naturaleza no lineal de

estos algoritmos y su sensibilidad a la distribución de los datos, se empleó el Error Absoluto Medio (MAE) mencionado anteriormente, proporcionando una base de comparación intuitiva. Paralelamente, se utilizó la Raíz del Error Cuadrático Medio (RMSE) para penalizar de forma más estricta las desviaciones de mayor escala, permitiendo identificar cuál de los dos modelos presenta una mayor robustez frente a valores atípicos. Finalmente, la capacidad explicativa de ambos modelos fue validada mediante el Coeficiente de Determinación ($R^2$), que también fue utilizado en la prueba inicial y facilitará la determinación de la superioridad estadística de un algoritmo sobre el otro en el contexto de este estudio.

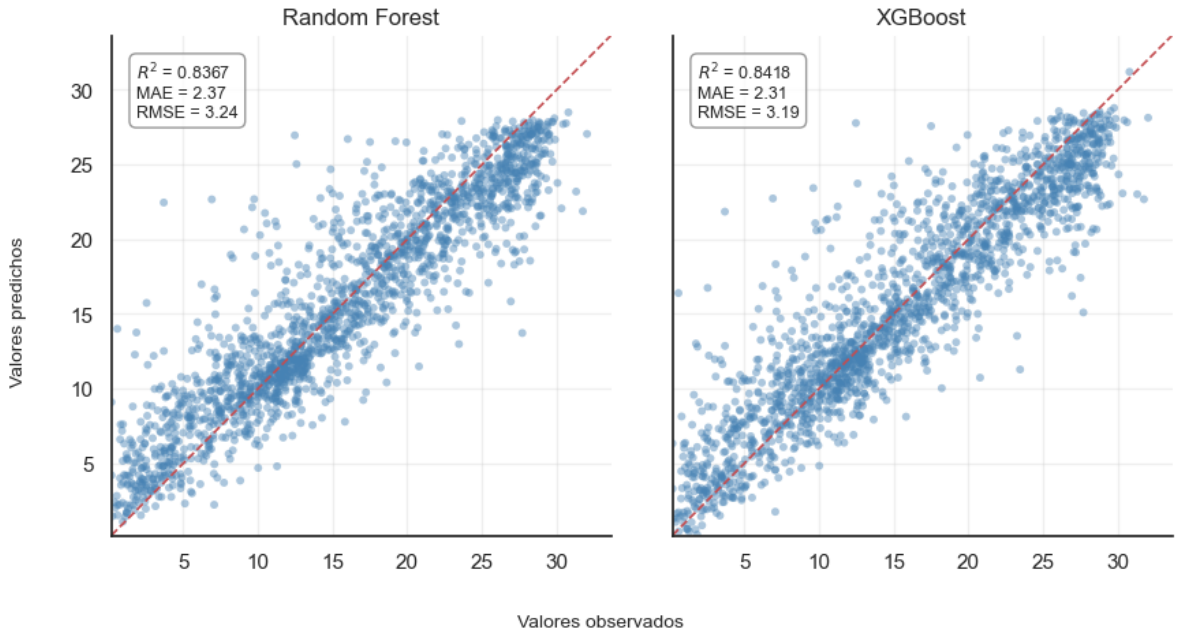


Gráfico 10: Valores observados vs. predichos

Para caracterizar la estabilidad y confiabilidad de las predicciones, se estimaron intervalos de incertidumbre mediante un procedimiento de bootstrap. Este método consiste en reentrenar cada modelo sobre 100 submuestras aleatorias con reemplazo del conjunto de entrenamiento y registrar la distribución de predicciones resultante para cada observación del conjunto de prueba. Al resultar demasiado costoso computacionalmente, se redujeron la cantidad de submuestras a 50 submuestras, sin perder demasiada precisión en el intervalo.

A partir de esta distribución empírica se calcularon los percentiles 10 y 90, que delimitan un intervalo de predicción del 80 %, junto con la media de las predicciones como estimador puntual. La representación gráfica de estos intervalos permite identificar regiones del espacio de entrada donde el modelo presenta mayor variabilidad entre submuestras y, por ende, menor certeza en sus predicciones. Este análisis complementa las métricas globales de rendimiento

($R^2$, MAE y RMSE) al aportar información local sobre la confianza del modelo en distintos rangos de la variable objetivo.

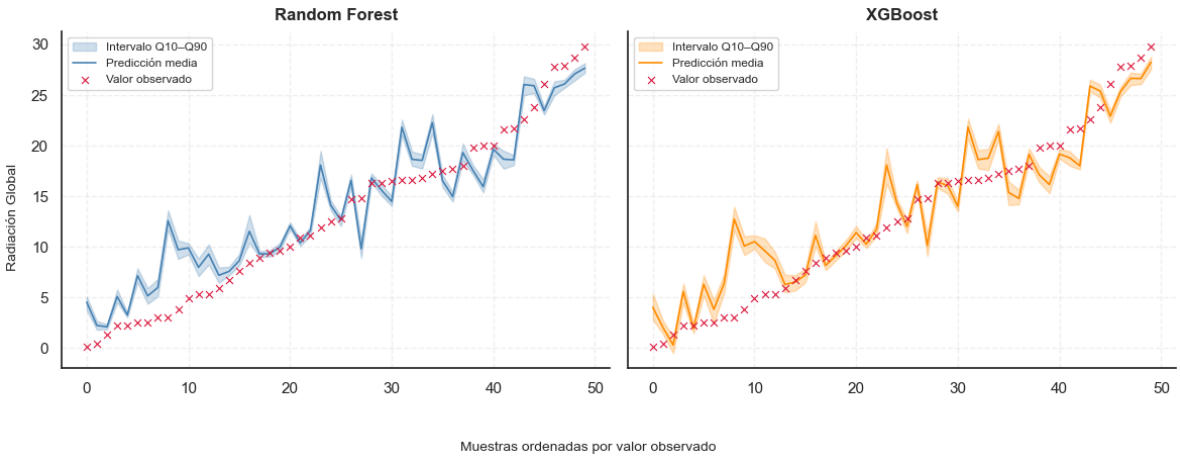


Gráfico 11: Confianza/Incertidumbre asociada a las predicciones

## Interpretabilidad de los modelos

El análisis de importancia de variables revela patrones consistentes entre ambos modelos. La componente cíclica del mes (mes_cos) emerge como el predictor dominante en ambos algoritmos, confirmando la fuerte estacionalidad de la radiación global y validando su codificación trigonométrica.

En Random Forest, la temperatura máxima bajo abrigo y la humedad media presentan contribuciones prácticamente equivalentes, sugiriendo que aportan información complementaria sobre las condiciones atmosféricas, mientras que la temperatura del suelo y la precipitación actúan como indicadores indirectos de nubosidad y humedad superficial. En XGBoost la jerarquía es cualitativamente similar pero más polarizada, con la humedad media y la precipitación ocupando el segundo y tercer lugar, desplazando a la temperatura máxima al cuarto puesto.

Esta diferencia entre modelos es esperable dado que XGBoost, al construir árboles secuencialmente, tiende a amplificar la dominancia de los predictores más informativos en las primeras iteraciones del proceso de boosting.

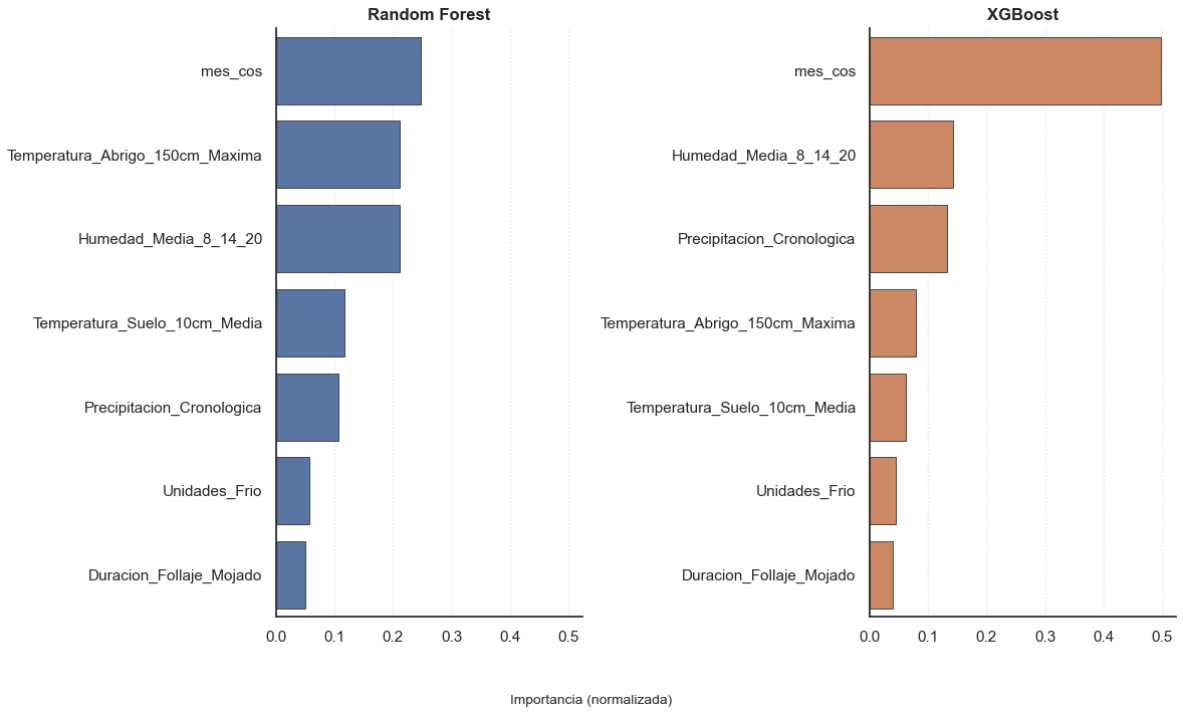


Gráfico 12: Importancia relativa de las variables.

## Conclusiones

El presente trabajo abordó la predicción de la radiación solar global a partir de variables climáticas registradas por estaciones meteorológicas, mediante un flujo de trabajo que integró el preprocesamiento de datos, el análisis exploratorio y la aplicación de modelos de aprendizaje automático basados en ensambles de árboles de decisión.

El proceso de Extracción, Transformación y Limpieza culminó en un dataframe con una leve tasa de descarte, a comparación del dataset inicial, evidenciando que los criterios de imputación y transformación adoptados permitieron preservar la gran mayoría de la información original sin necesidad de recurrir a la eliminación masiva de registros. Aquellos criterios establecidos para el tratamiento de valores faltantes (diferenciando entre interpolación lineal para huecos cortos e imputación por KNN para huecos de mayor extensió) y para la transformación de valores atípicos, permitieron preservar la distribución estadística de las variables y evitar la introducción de sesgos artificiales en las etapas de modelado.

El análisis exploratorio, apoyado en múltiples visualizaciones, permitió caracterizar el comportamiento individual y conjunto de las variables climáticas disponibles, facilitando la selección de variables predictoras. Este proceso de selección resultó determinante para alcanzar métricas de rendimiento satisfactorias en ambos modelos. Tanto el modelo de Random Forest como el

XGBoost evidencian una capacidad predictiva robusta y una generalización satisfactoria ante datos no observados durante el entrenamiento.

Como líneas de trabajo futuro, resultaría de interés explorar la incorporación de otros algoritmos de aprendizaje automático que permitan contrastar los resultados obtenidos en un marco comparativo más amplio. Asimismo, sería valioso avanzar en la reducción del conjunto de variables predictoras, buscando identificar la combinación mínima que preserve la robustez predictiva de los modelos, lo que contribuiría tanto a la interpretabilidad como a la eficiencia computacional en escenarios de aplicación operativa.

## Referencias


Allaire, J. J., Teague, C., Scheidegger, C., Xie, Y., Dervieux, C., & Woodhull, G. (2025). *Quarto* (Versión 1.8) [Software]. https://doi.org/10.5281/zenodo.5960048

Gentile, E., Martin, P. y Gatti, I. (2020). *Argentina físico-natural: Clima. ANIDA. Atlas Nacional Interactivo de Argentina.* Instituto Geográfico Nacional. https://static.ign.gob.ar/anida/fasciculos/fasc_afn_clima.pdf

Iannone, R., Cheng, J., Schloerke, B., Haughton, S., Hughes, E., Lauer, A., François, R., Seo, J., Brevoort, K., & Roy, O. (2026). *gt: Easily Create Presentation-Ready Display Tables.* https://gt.rstudio.com

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, *12*, 2825-2830. https://jmlr.csail.mit.edu/papers/v12/pedregosa11a.html

Wikipedia, La enciclopedia libre. (s. f.). *Provincia de Corrientes.* Recuperado https://es.wikipedia.org/wiki/Provincia_de_Corrientes