Trabajo Final: Aplicaciones de Inteligencia de Datos

Maestría en Ciencia de Datos - Universidad Nacional Arturo Jauretche

Raúl Burgos, Mauro Cejas Marcovecchio, Raúl Muñóz, Mirta Soto

Contenido

1 Descripción **2**

2 EDA y Preprocesamiento **2**

Preprocesamiento básico y limpieza inicial 2

Cantidad de registros, variables y tipos 3

Resumen estadístico 6

Visualizaciones y limpieza avanzada de datos 7

Preprocesamiento y limpieza avanzada de datos 12

3 Modelado, Evaluación e Interpretabilidad **13**

Selección de modelos 13

Entrenamiento, validación y optimización de modelos 13

Evaluación y análisis de resultados 15

Interpretabilidad de los modelos 16

Conclusiones 16

Referencias **16**

1. Descripción

El objetivo del siguiente trabajo es el análisis exploratorio, procesamiento de datos y el desarrollo de modelos de machine learning para la predicción de la radiación global. El dataset utilizado fue obtenido a partir del Sistema de Información y Gestión Agrometeorológica (SIGA), del Instituto Nacional de Tecnología Agropecuaria (INTA). Esta base de datos contiene información de tres estaciones meteorológicas ubicadas en las localidades de Goya, Bella Vista y Herliszka, en la Provincia de Corrientes, Argentina. El repositorio completo del proyecto se encuentra disponible en el enlace: https://github.com/cejasmau/tp_aplicaciones

El clima de esta provincia puede ser caracterizado según la clasificación climática Koppen como subtropical sin estación seca, destacando el clima subtropical húmedo en el noreste. Según el último informe agroclimático anual de Bella Vista publicado por el INTA en 2020, la temperatura media mensual osciló entre los 14.8 y 26.9 °C. Las precipitaciones son abundantes en Corrientes, en la que el promedio anual histórico se ubica en los 1,258.5 mm de lluvia, aunque durante el año mencionado se haya registrado una caída considerable, con 794.7 mm anuales. Los periodos lluviosos se dan especialmente en los equinoccios de otoño y primavera, siendo el invierno y el verano las estaciones más secas del año. Los veranos son muy sofocantes: las temperaturas máximas en 2020 llegaron a los 40 °C, sumadas a la elevada humedad del ambiente. En cambio los inviernos son templados-fríos. Los vientos que más afectan a la provincia son el norte muy cálido proveniente de Brasil, el pampero frío y seco proveniente de la Patagonia y la sudestada frío y húmedo proveniente del mar argentino.

2. EDA y Preprocesamiento

Preprocesamiento básico y limpieza inicial

El punto de partida del trabajo serán los tres datasets provistos, uno por cada estación meteorológica. A partir de ellos, podremos comprobar que todos están compuestos por las mismas 30 variables. Por lo tanto, luego de incorporar al dataset el nombre de la localidad de cada estación, procederemos a unificarlos en una sola base de datos.

Al comprobar que las tres localidades están ubicadas a distancias relativamente cercanas y en alturas sobre el nivel del mar similares (de 57 a 66 m.s.n.m.), factores que podrían haber sido determinantes sobre nuestra variable objetivo, se decidió no incorporar estos datos al análisis.

```
Dimensiones del dataset de Goya: (3939, 30)
Dimensiones del dataset de Bella Vista: (3714, 30)
Dimensiones del dataset de Herlitzka: (2220, 30)
```

Cantidad de registros, variables y tipos

De esta manera, dispondremos de un total de 9873 registros y 31 variables. Aún así, a lo largo de esta etapa del trabajo se irán descartando aquellas variables que no tengan la suficiente calidad, cantidad o representatividad como para formar parte del conjunto de variables explicativas que nos permitan predecir la radiación global, como ya se ha mencionado.

En ese sentido, podremos comprobar que las variables vinculadas a la medición de la temperatura a la intemperie y el suelo a 5 cm de altura no tendrán valores válidos. Tampoco los tendrá la variable que mide la humedad del suelo. Por este motivo, se procederá a descartarlas.

Asimismo, las variables vinculadas a la Heliofanía serán excluidas del dataset y su posterior análisis, ya que se trata de fenómenos físicos intrínsicamente ligados a la radiación solar. Su inclusión, en vez de permitir la identificación de factores subyacentes que la expliquen, daría como resultado una predicción casi perfecta pero carente de utilidad analítica.

Por último, viendo que las Temperaturas a la Intemperie a 50 y 150 cm Mínimas tienen aproximadamente el 85 % de valores faltantes, vamos a descartarlas también.

Variables	Expresada en (unidades)	Tipo	Valores no nulos	Valores faltantes
Fecha	-	Fecha/Hora	9873	0
Temperatura_Abrigo_150cm	°C	Numérico	9508	365
Temperatura_Abrigo_150cm_Maxima	°C	Numérico	9493	380
Temperatura_Abrigo_150cm_Minima	°C	Numérico	9487	386
Temperatura_Intemperie_5cm_Minima	°C	NA	0	9873
Temperatura_Intemperie_50cm_Minima	°C	Numérico	1404	8469
Temperatura_Suelo_5cm_Media	°C	NA	0	9873
Temperatura_Suelo_10cm_Media	°C	Numérico	9116	757
Temperatura_Inte_5cm	°C	NA	0	9873
Temperatura_Intemperie_150cm_Minima	°C	Numérico	1412	8461
Humedad_Suelo	%	NA	0	9873
Precipitacion_Pluviometrica	mm	Numérico	9149	724
Precipitacion_Cronologica	mm	Numérico	9129	744
Precipitacion_Maxima_30minutos	mm	Numérico	8324	1549
Heliofania_Efectiva	h	Numérico	7942	1931
Heliofania_Relativa	%	Numérico	7939	1934
Tesion_Vapor_Media	hPa	Numérico	9437	436
Humedad_Media	%	Numérico	9502	371
Humedad_Media_8_14_20	%	Numérico	9475	398
Rocio_Medio	°C	Numérico	8754	1119
Duracion_Follaje_Mojado	h	Numérico	9041	832
Velocidad_Viento_200cm_Media	km/h	Numérico	8998	875
Direccion_Viento_200cm	-	Texto	9566	307
Velocidad_Viento_1000cm_Media	km/h	Numérico	8998	875
Direccion_Viento_1000cm	-	Texto	9566	307
Velocidad_Viento_Maxima	km/h	Numérico	9049	824
Presion_Media	Pa	Numérico	9041	832
Radiacion_Global	MJ/m2	Numérico	9041	832
Horas_Frio	h	Numérico	9426	447
Unidades_Frio	-	Numérico	9427	446
Localidad	-	Texto	9873	0

Gráfico 1: Resumen exploratorio de variables del dataset.

Así, podremos ver que el dataset estará compuesto por tipos de datos categóricos (aquellos referidos a la dirección del viento y al nombre de la localidad), temporales (fecha) y numéricos (todos los demás).

Valores faltantes, duplicados e inconsistencias

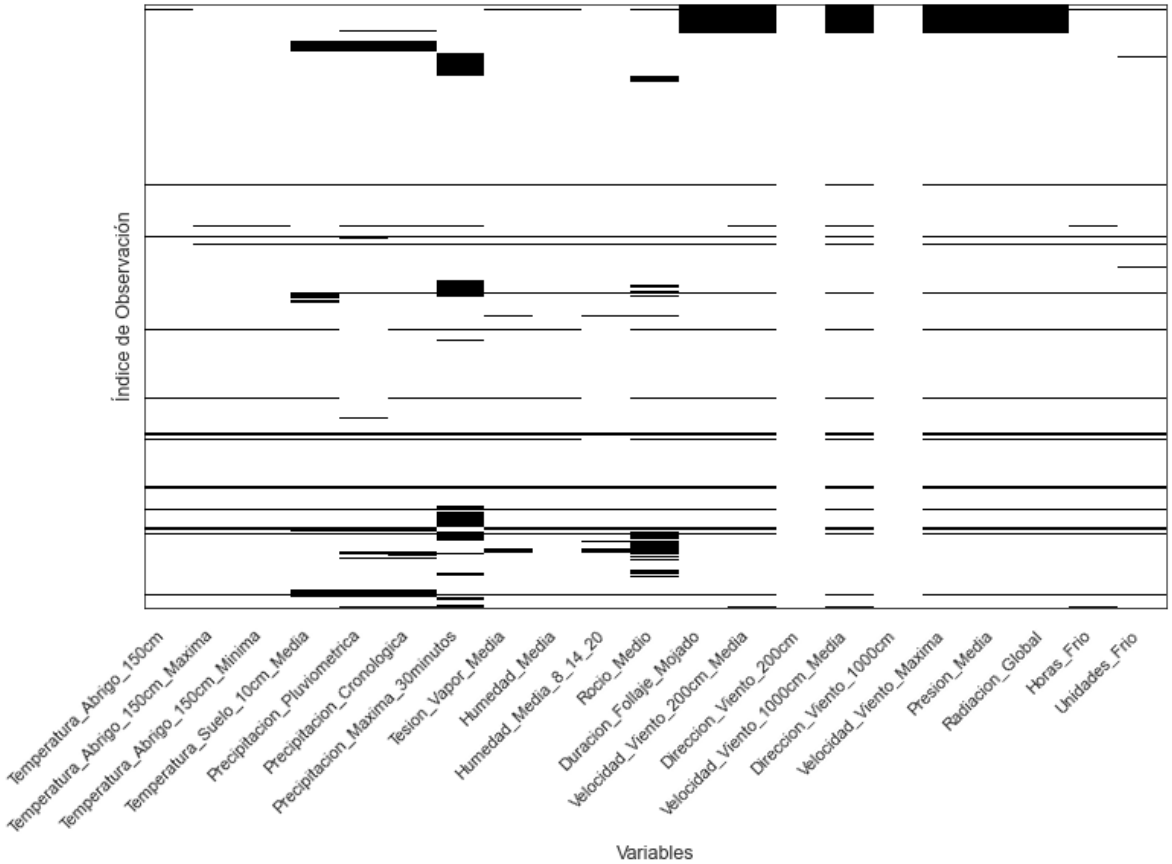

Gráfico 2: Mapa de valores faltantes en el conjunto de datos

Como podemos observar en el mapa, hay múltiples filas en las que se encuentran faltantes en todas las columnas menos en las referidas a la Dirección del viento y la fecha. Por lo tanto, vamos a identificarlas y descartarlas.

Además, puede notarse que la variable objetivo del trabajo, la radiación global, posee una gran cantidad de valores faltantes, principalmente al inicio de los registros del dataset. Teniendo en cuenta que nuestro objetivo será su predicción, deberemos descartar los registros en los que esta variable presente valores nulos.

Resulta interesante notar que las variables asociadas a la dirección y velocidad del viento presentan un comportamiento inconsistente que compromete su utilidad como predictores. Al exhibir una proporción considerable de valores nulos e inconsistencias en su registro y que la relación entre el viento y la radiación solar sea indirecta y de baja magnitud, fueron descartadas del conjunto de variables analizadas.

Resumen estadístico

Variables	min	X25.	X50.	mean	X75.	max	IQR	Moda	std
Temperatura_Abrigo_150cm	3.41	17.32	21.97	21.29	25.57	42.96	8.25	24.91	5.63
Temperatura_Abrigo_150cm_Maxima	9.50	23.60	28.50	27.97	32.70	60.00	9.10	29.70	6.38
Temperatura_Abrigo_150cm_Minima	−28.10	12.10	16.70	15.91	20.30	43.30	8.20	19.80	5.77
Temperatura_Suelo_10cm_Media	−6.80	19.12	23.94	23.70	27.90	50.00	8.78	27.58	5.89
Precipitacion_Pluviometrica	0.00	0.00	0.00	3.16	0.20	169.00	0.20	0.00	11.49
Precipitacion_Cronologica	0.00	0.00	0.00	3.17	0.00	220.00	0.00	0.00	11.94
Precipitacion_Maxima_30minutos	0.00	0.00	0.00	1.25	0.00	58.20	0.00	0.00	4.47
Tesion_Vapor_Media	0.01	14.41	19.22	19.45	24.27	73.20	9.86	11.67	6.90
Humedad_Media	0.00	65.00	77.00	74.63	87.00	100.00	22.00	100.00	17.65
Humedad_Media_8_14_20	3.00	62.00	75.00	73.26	86.00	100.00	24.00	100.00	17.23
Rocio_Medio	−7.96	12.83	17.07	16.49	20.72	34.39	7.89	10.56	5.62
Duracion_Follaje_Mojado	0.00	0.00	1.08	3.57	6.77	24.00	6.77	0.00	4.58
Presion_Media	986.28	1,000.38	1,004.11	1,004.73	1,008.71	1,033.71	8.33	1,004.44	6.12
Radiacion_Global	0.02	9.59	15.17	15.51	22.14	32.27	12.55	4.24	7.86
Horas_Frio	0.00	0.00	0.00	0.54	0.00	18.92	0.00	0.00	2.09
Unidades_Frio	−23.90	−23.90	−21.33	−15.87	−10.54	19.51	13.36	−23.90	10.70

Gráfico 3: Resumen de estadísticas descriptivas de las variables.

Visualizaciones y limpieza avanzada de datos

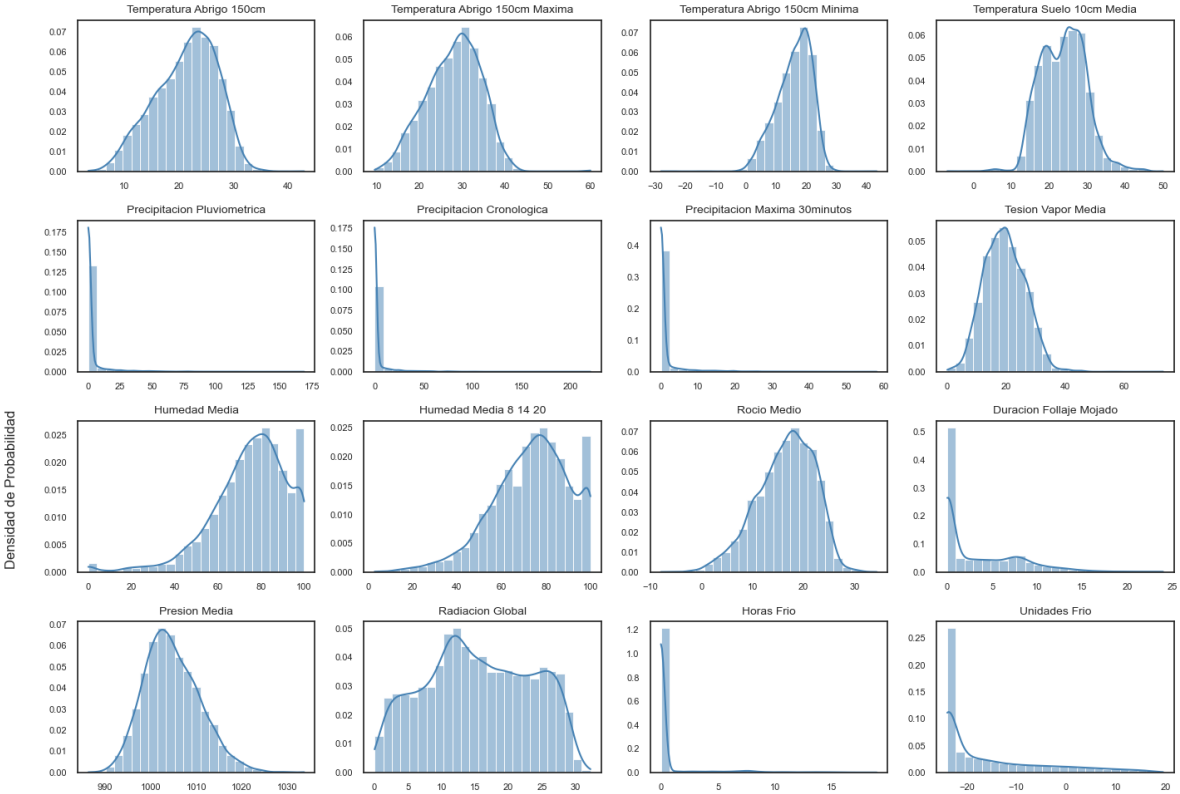

Gráfico 4: Distribución de frecuencias y densidad de probabilidad de las variables

En primer lugar, mediante los gráficos de distribución de frecuencias, puede comprobarse que las variables vinculadas a la temperatura, la radiación global, la tesión de vapor, rocío y presión medias, presentan distribuciones aproximadamente simétricas. Por su parte, las vinculadas a la humedad tendrán sesgos a la derecha. Finalmente, las precipitaciones, duración del follaje mojado y las horas y unidades de frío tendrán distribuciones más próximas a una distribución gamma que a una normal.

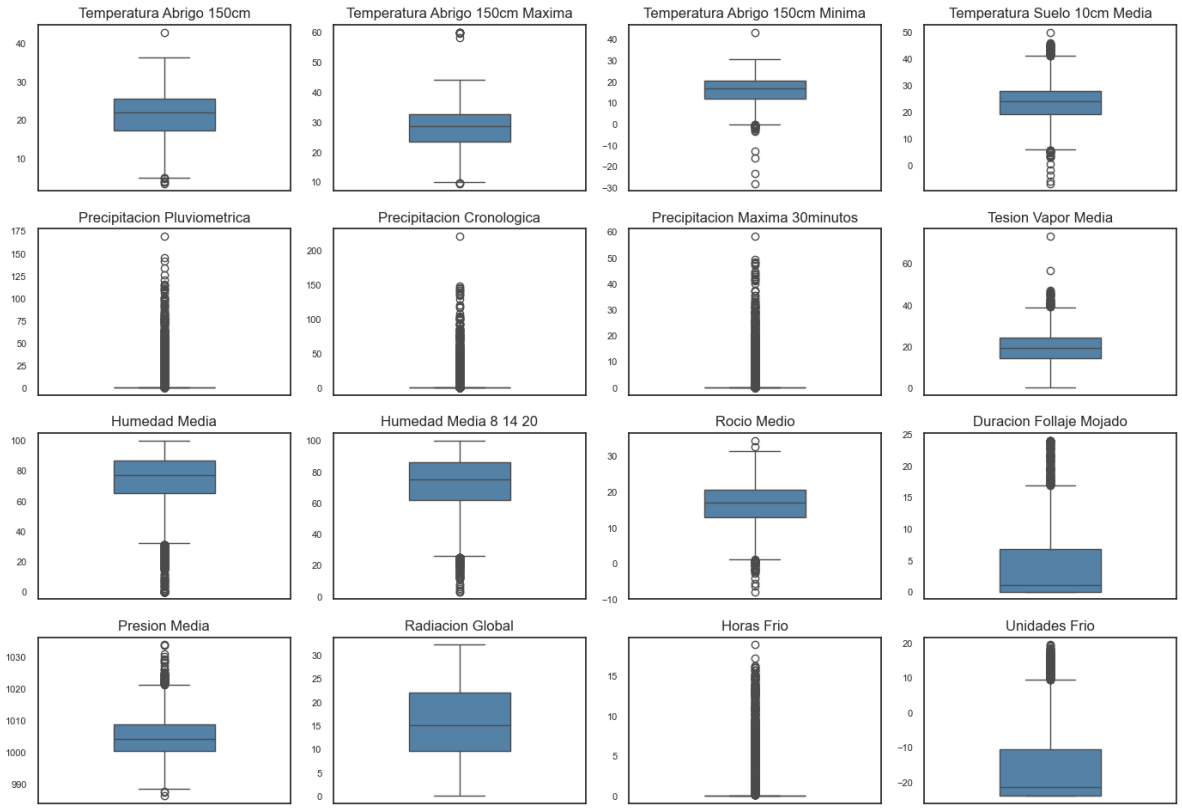

Gráfico 5: Diagramas de cajas y bigotes

En segundo lugar, el análisis de los diagramas de caja y bigotes revela que la mayoría de las variables presentan *outliers*, es decir, observaciones que se desvían considerablemente de los límites definidos por los percentiles 25 y 75 (inferior y superior). Las excepciones son la radiación global y, en menor medida, las variables de temperatura de abrigo, que exhiben una dispersión más contenida. Las variables asociadas a las precipitaciones y las horas de frío son las que concentran la mayor presencia de valores extremos.

Dado que la presencia de valores atípicos puede afectar medidas como la media y la desviación estándar, distorsionar la representación gráfica de los datos y reducir el rendimiento de los modelos de aprendizaje automático, más adelante se procederá a su identificación para determinar, en cada caso, si corresponde su transformación o eliminación del conjunto de datos.

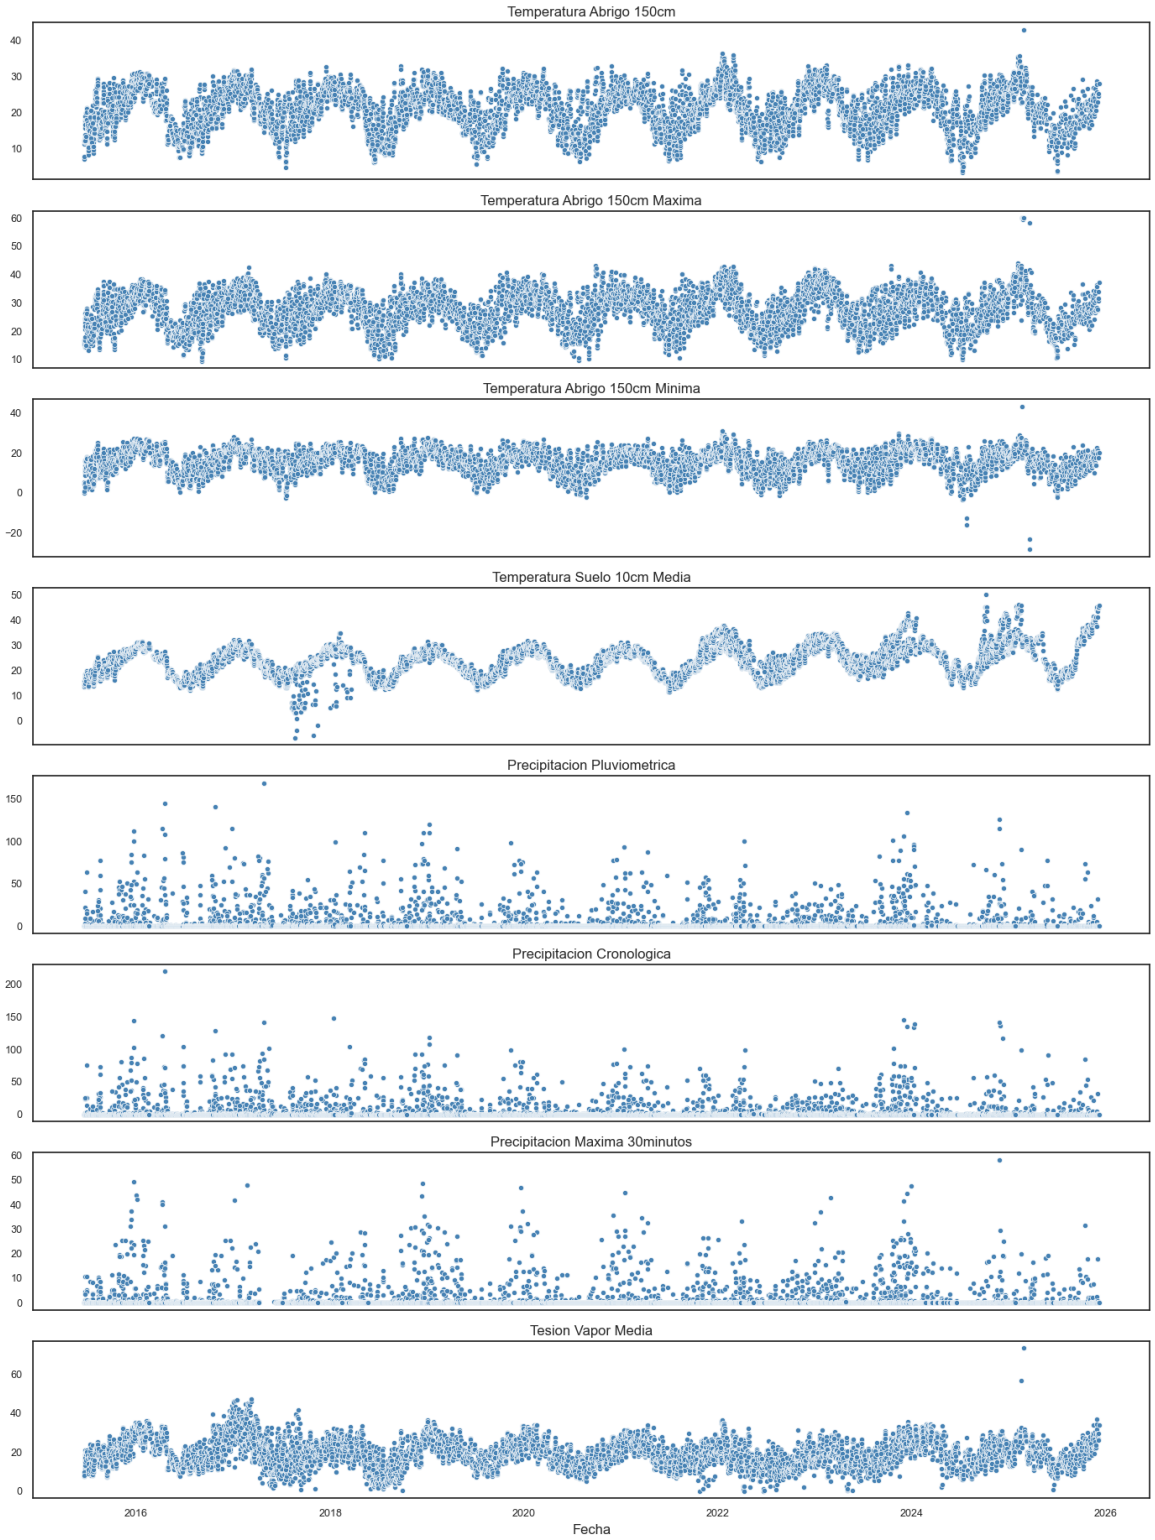

Gráfico 6: Series temporales de las variables estudiadas (I)

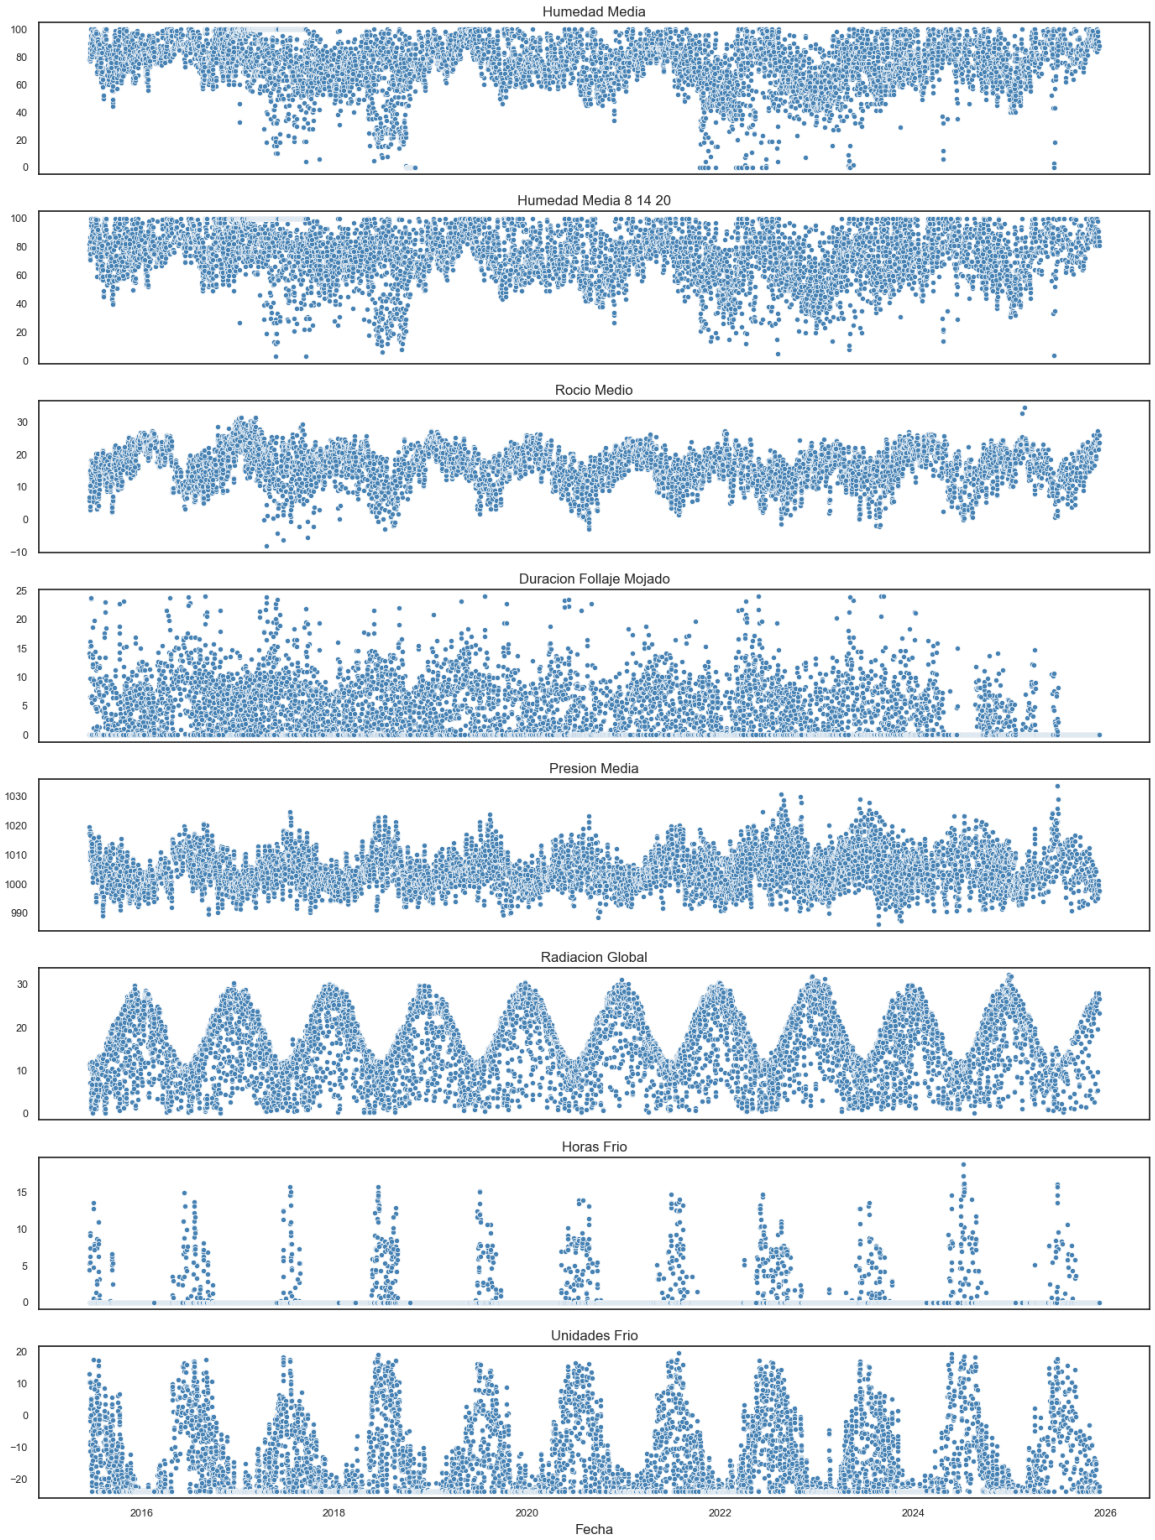

Gráfico 7: Series temporales de las variables estudiadas (II)

En tercer lugar, a partir de los gráficos de dispersión puede notarse claramente el componente estacional de los datos. Dado que los meses tienen una naturaleza cíclica, su incorporación como una variable numérica lineal no nos permitiría comprender los patrones estacionales apropiadamente. Para preservar esta continuidad, se aplicó una transformación cíclica que proyecta los meses sobre un círculo unitario, de modo que la distancia entre meses consecutivos —incluyendo la transición de diciembre a enero— sea uniforme y matemáticamente coherente.

$$mes_sin = \sin\left(\frac{2\pi \cdot mes}{12}\right), \quad mes_cos = \cos\left(\frac{2\pi \cdot mes}{12}\right)$$

Si bien esta transformación genera dos componentes (seno y coseno), el coseno tiende a correlacionar mejor con variables que tienen su pico en invierno o verano, por lo que tendrá sentido que capture mejor la relación con la radiación global.

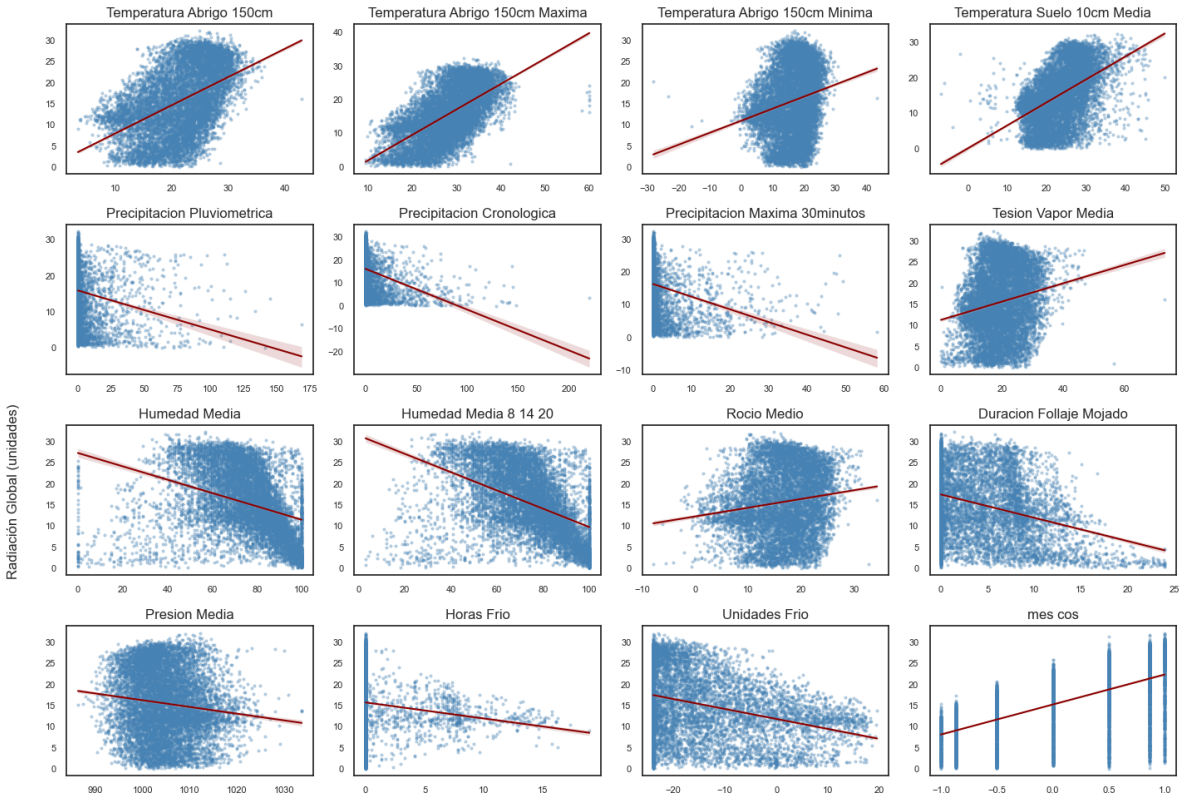

Gráfico 8: Relación entre la radiación global y las variables estudiadas

Por último, a través de los gráficos que relacionan la radiación global y el resto de las variables, junto con la matriz de correlación, puede identificarse que algunas de ellas presentan

coeficientes de Pearson estadísticamente significativos, tanto con la variable objetivo como entre sí. Este último aspecto resulta relevante, ya que la presencia de multicolinealidad entre predictores puede afectar la interpretación y el rendimiento de ciertos modelos.

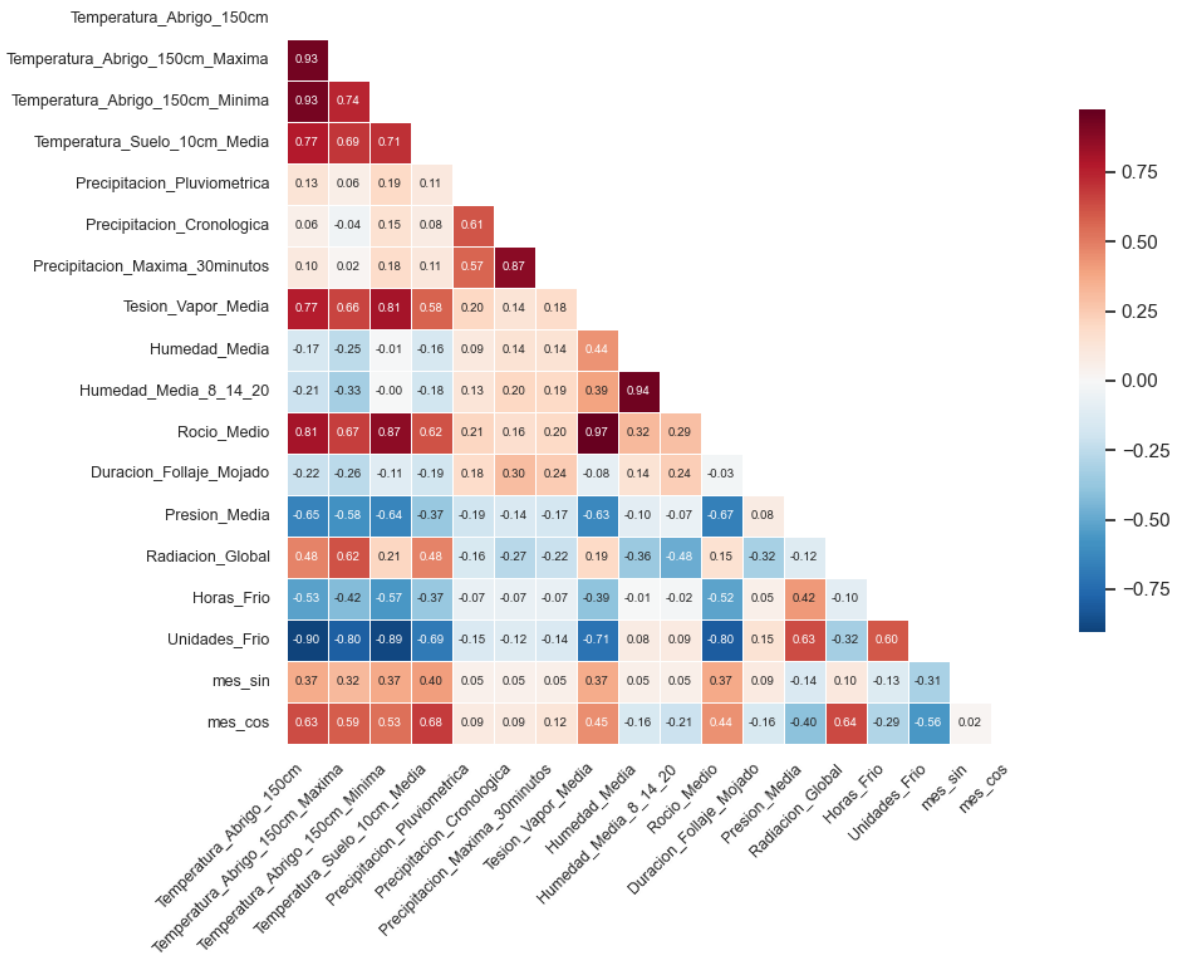

Gráfico 9: Matriz de correlación de Pearson para las variables estudiadas

Preprocesamiento y limpieza avanzada de datos

Con el objetivo de establecer una estrategia para el tratamiento de outliers, se consideraron dos grupos de variables según la forma que tomó su distribución. Para aquellas variables con una distribución similar a la normal, se aplicó un techo basado en tres desviaciones estándar, buscando mitigar el impacto de los valores extremos. Por otro lado, para las variables con una distribución similar a la gamma, dada la asimetría positiva de las variables meteorológicas

analizadas, se aplicó un techo basado en percentiles (fijando el límite superior en el percentil 99.5)

El tratamiento de valores faltantes se realizó mediante dos etapas, diferenciando el método de imputación según la cantidad de días consecutivos sin información. Se estableció un umbral de tres días como criterio de separación. Para períodos de hasta tres días se aplicó interpolación lineal, que se aplicó de forma independiente para cada estación meteorológica.

Sobre los períodos de más de tres días, se empleó el algoritmo *K-Nearest Neighbors* (KNN). Este método imputa cada valor faltante como una combinación ponderada de los k vecinos más similares en el espacio multivariado, aprovechando la correlación espacial y temporal entre variables. Aún así, antes de aplicar el tratamiento, se estandarizaron las variables mediante z-score, transformación necesaria para el algoritmo KNN: sin estandarización, las variables con mayor magnitud o varianza dominarían el cálculo de distancias, introduciendo un sesgo sistemático en la selección de vecinos. Tras la imputación, los valores fueron reescalados a su escala original mediante la transformación inversa.

Finalmente, ya que los modelos de Machine Learning solo procesan valores numéricos, vamos a transformar la única variable categórica que nos queda (Localidad) mediante el método One-Hot Encoding, recomendado para para modelos de regresiones, algoritmos de aprendizaje automático supervisado (SVM) y redes neuronales.

3. Modelado, Evaluación e Interpretabilidad

Selección de modelos

Se seleccionaron los modelos Random Forest y XG Boost debido a su capacidad para modelar interacciones complejas entre variables climáticas. Por un lado Random Forest ofrece una base estable y fácil de interpretar, captura de no linealidad, robustez frente a los outliers e importancia de las variables (permite cuantificar cuanto aporta cada variable a la predicción). Mientras que el XGboost permite maximizar la precisión predictiva mediante el ajuste de hiperparámetros. Este modelo entrena los árboles de forma secuencial, donde cada nuevo árbol aprende de los errores del anterior. Podemos destacar su alta precisión, manejo de datos faltantes y regularización (incluye técnicas de sobreajuste).

Entrenamiento, validación y optimización de modelos

Para la evaluación del rendimiento de los modelos, se adoptó un esquema de validación *Hold-out*, mediante el cual el conjunto de datos se particionó en dos subconjuntos: un conjunto de entrenamiento, correspondiente al 80 % de las observaciones, y un conjunto de prueba, conformado por el 20 % restante.

El subconjunto de entrenamiento fue utilizado para ajustar los parámetros de cada modelo a partir de las relaciones existentes entre las variables climáticas predictoras y la radiación solar. El subconjunto de prueba, por su parte, se reservó exclusivamente para la evaluación final del rendimiento, garantizando que las métricas obtenidas reflejen la capacidad de generalización de los modelos ante datos no observados durante el entrenamiento.

Con el fin de asegurar la reproducibilidad de los experimentos, la partición se realizó fijando una semilla de aleatoriedad (random_state=42). Además, el desempeño de los modelos fue cuantificado mediante dos métricas complementarias. En primer lugar, el coeficiente de determinación (R^2), que expresa la proporción de la varianza de la variable objetivo explicada por el modelo. En segundo lugar, el error absoluto medio (MAE), que indica el promedio de las diferencias absolutas entre los valores observados y los predichos, es decir, cuántas unidades de radiación se equivoca el modelo en cada predicción.

```
--- Resultados Random Forest ---
R2 Score: 0.8309
MAE: 2.38

--- Resultados XGBoost ---
R2 Score: 0.8404
MAE: 2.31
```

La optimización de hiperparámetros se llevó a cabo mediante *RandomizedSearchCV*, que a diferencia de la búsqueda exhaustiva (*Grid Search*) explora muestras aleatorias del espacio de hiperparámetros, ofreciendo una reducción sustancial del costo computacional sin sacrificar significativamente la calidad de la solución encontrada. Como esquema de validación interna se empleó una validación cruzada de k = 5 pliegues (*5-Fold Cross-Validation*), en la que el conjunto de entrenamiento se dividió en cinco subconjuntos de igual tamaño. En cada iteración, el modelo fue entrenado sobre cuatro subconjuntos y evaluado sobre el restante, rotando sistemáticamente hasta que cada subconjunto actuó una vez como conjunto de validación. Este procedimiento reduce la dependencia del rendimiento estimado respecto de una partición arbitraria de los datos y favorece la generalización de los resultados a distintos períodos temporales.

Su objetivo se centró en equilibrar la capacidad de aprendizaje con la generalización. Para ambos algoritmos, se ajustó la cantidad de estimadores/árboles (*n_estimators*) y la profundidad máxima (*max_depth*), permitiendo configuraciones de crecimiento libre para capturar interacciones complejas en los datos. En el caso de RF, la robustez se reforzó mediante restricciones en la división de nodos (*min_samples_split* y *leaf*) y el uso de técnicas de *bootstrap*, comparando la construcción de árboles mediante re-muestreo con reemplazo frente al uso del conjunto de datos completo para optimizar la estabilidad de las predicciones. Por su parte, XGBoost incorporó un control del tamaño del paso en cada iteración del proceso de boosting mediante *learning_rate* y el parámetro *gamma*, el cual actúa como un umbral de

reducción mínima de pérdida para habilitar nuevas particiones. La reducción del sobreajuste en ambos modelos se garantizó mediante mecanismos de aleatoriedad: submuestreo de variables (*max_features*/*colsample_bytree*) y observaciones (*subsample*), además de la aplicación de regularización *L1* y *L2* en el caso de XGBoost, que penalizan la complejidad de los pesos en las hojas del modelo.

```
Mejor R2 RF: 0.8229


Mejores hiperparámetros:
  n_estimators: 500
  min_samples_split: 2
  min_samples_leaf: 2
  max_features: sqrt
  max_depth: None
  bootstrap: True


Mejor R2 XGB: 0.8278


Mejores hiperparámetros:
  subsample: 0.8
  reg_lambda: 1.5
  reg_alpha: 0.01
  n_estimators: 200
  max_depth: 6
  learning_rate: 0.05
  gamma: 0
  colsample_bytree: 0.6
```

Evaluación y análisis de resultados

Evaluar y comparar el desempeño de los modelos utilizando métricas adecuadas para el problema.

Visualizar y analizar el output de los modelos, incluyendo comparaciones entre valores reales y predichos sobre el conjunto de test.

Detallar y representar gráficamente la "confianza" o incertidumbre asociada a las predicciones, cuando corresponda.

Interpretabilidad de los modelos

Realizar un análisis de interpretabilidad de los modelos entrenados, identificando las variables más relevantes y discutiendo su impacto en las predicciones.

Conclusiones

Elaborar conclusiones integradoras a partir de los resultados obtenidos, destacando fortalezas, limitaciones y posibles mejoras

Referencias

Allaire, J. J., Teague, C., Scheidegger, C., Xie, Y., Dervieux, C., & Woodhull, G. (2025). *Quarto* (Versión 1.8) [Software]. https://doi.org/10.5281/zenodo.5960048

Gentile, E., Martin, P. y Gatti, I. (2020). *Argentina físico-natural: Clima. ANIDA. Atlas Nacional Interactivo de Argentina.* Instituto Geográfico Nacional. https://static.ign.gob.ar/anida/fasciculos/fasc_afn_clima.pdf

Iannone, R., Cheng, J., Schloerke, B., Haughton, S., Hughes, E., Lauer, A., François, R., Seo, J., Brevoort, K., & Roy, O. (2026). *gt: Easily Create Presentation-Ready Display Tables*. https://gt.rstudio.com

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, *12*, 2825-2830. https://jmlr.csail.mit.edu/papers/v12/pedregosa11a.html

Wikipedia, La enciclopedia libre. (s. f.). *Provincia de Corrientes*. Recuperado https://es.wikipedia.org/wiki/Provincia_de_Corrientes