Trabajo Final: Aplicaciones de Inteligencia de Datos

Maestría en Ciencia de Datos - Universidad Nacional Arturo Jauretche

Raúl Burgos, Mauro Cejas Marcovecchio, Raúl Muñóz, Mirta Soto

Contenido

1 Descripción **1**

2 EDA y Preprocesamiento **2**
Preprocesamiento básico y limpieza inicial . . . 2
Cantidad de registros y variables . . . 2
Tipos de variables . . . 4
Valores atípicos . . . 7
Resumen estadístico . . . 11
Visualizaciones: análisis bivariado y multivariado . . . 13
Preprocesamiento y limpieza avanzada de datos. . . . 14
Conclusiones parciales . . . 14

3 Modelado, Evaluación e Interpretabilidad **14**
Selección de modelos . . . 14
Entrenamiento, validación y optimización de modelos . . . 15
Evaluación y análisis de resultados . . . 15
Interpretabilidad de los modelos . . . 15
Conclusiones . . . 15

Referencias **15**

1. Descripción

El objetivo del siguiente trabajo es el análisis exploratorio, preprocesamiento de datos y el desarrollo de modelos de machine learning para la predicción de la radiación global. El dataset utilizado fue obtenido a partir del Sistema de Información y Gestión Agrometeorológica (SIGA),

del Instituto Nacional de Tecnología Agropecuaria (INTA). Esta base de datos contiene información de tres estaciones meteorológicas ubicadas en las localidades de Goya, Bella Vista y Herliszka, en la Provincia de Corrientes, Argentina.

El clima de esta provincia puede ser caracterizado según la clasificación climática Koppen como subtropical sin estación seca, destacando el clima subtropical húmedo en el noreste. Según el último informe agroclimático anual de Bella Vista publicado por el INTA en 2020, la temperatura media mensual osciló entre los 14.8 y 26.9 °C. Las precipitaciones son abundantes en Corrientes, en la que el promedio anual histórico se ubica en los 1,258.5 mm de lluvia, aunque durante el año mencionado se haya registrado una caída considerable, con 794.7 mm anuales. Los periodos lluviosos se dan especialmente en los equinoccios de otoño y primavera, siendo el invierno y el verano las estaciones más secas del año. Los veranos son muy sofocantes: las temperaturas máximas en 2020 llegaron a los 40 °C, sumadas a la elevada humedad del ambiente. En cambio los inviernos son templados-fríos. Los vientos que más afectan a la provincia son el norte muy cálido proveniente de Brasil, el pampero frío y seco proveniente de la Patagonia y la sudestada frío y húmedo proveniente del mar argentino.

2. EDA y Preprocesamiento

Preprocesamiento básico y limpieza inicial

El punto de partida del trabajo serán los tres datasets provistos, uno por cada estación meteorológica. A partir de ellos, podremos comprobar que todos están compuestos por las mismas 33 variables. Por lo tanto, luego de incorporar la ubicación geográfica de cada estación, es decir, su latitud, longitud y el nombre de la localidad correspondiente, procederemos a unificarlos en una sola base de datos. Al comprobar que las tres localidades están ubicadas en alturas sobre el nivel del mar similares (de 57 a 66 m.s.n.m.), factor que podría haber sido determinante sobre nuestra variable objetivo, se decidió no incorporarlo al análisis.

```
Dimensiones Goya: (3939, 30)
Dimensiones Bella Vista: (3714, 30)
Dimensiones Herlitzka: (2220, 30)
```

```
(9873, 33)
```

Cantidad de registros y variables

De esta manera, dispondremos de un total de 9873 registros y 36 variables. Aún así, a lo largo de esta etapa del trabajo se irán descartando aquellas variables que no tengan la suficiente calidad, cantidad o representatividad como para formar parte del conjunto de variables explicativas que nos permitan predecir la radiación global, como ya se ha mencionado.

En este caso, podremos comprobar que las variables vinculadas a la medición de la temperatura a la intemperie y el suelo a 5 cm de altura no tendrán valores válidos. Tampoco los tendrá la variable que mide la humedad del suelo. Por este motivo, se procederá a descartarlas.

Asimismo, las variables vinculadas a la Heliofanía serán excluidas del dataset y su posterior análisis, ya que se trata de fenómenos físicos intrínsicamente ligados a la radiación solar. Su inclusión, en vez de permitir la identificación de factores subyacentes que la expliquen, daría como resultado una predicción casi perfecta pero carente de utilidad analítica.

Por último, viendo que las Temperaturas a la Intemperie a 50 y 150 cm Mínimas tienen aproximadamente el 85 % de valores faltantes, vamos a descartarlas también.

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 9873 entries, 0 to 9872
Data columns (total 33 columns):
 #   Column                                Non-Null Count  Dtype
---  ------                                --------------  -----
 0   Fecha                                 9873 non-null   object
 1   Temperatura_Abrigo_150cm              9508 non-null   float64
 2   Temperatura_Abrigo_150cm_Maxima       9493 non-null   float64
 3   Temperatura_Abrigo_150cm_Minima       9487 non-null   float64
 4   Temperatura_Intemperie_5cm_Minima     0 non-null      float64
 5   Temperatura_Intemperie_50cm_Minima    1404 non-null   float64
 6   Temperatura_Suelo_5cm_Media           0 non-null      float64
 7   Temperatura_Suelo_10cm_Media          9116 non-null   float64
 8   Temperatura_Inte_5cm                  0 non-null      float64
 9   Temperatura_Intemperie_150cm_Minima   1412 non-null   float64
 10  Humedad_Suelo                         0 non-null      float64
 11  Precipitacion_Pluviometrica           9149 non-null   float64
 12  Precipitacion_Cronologica             9129 non-null   float64
 13  Precipitacion_Maxima_30minutos        8324 non-null   float64
 14  Heliofania_Efectiva                   7942 non-null   float64
 15  Heliofania_Relativa                   7939 non-null   float64
 16  Tesion_Vapor_Media                    9437 non-null   float64
 17  Humedad_Media                         9502 non-null   float64
 18  Humedad_Media_8_14_20                 9475 non-null   float64
 19  Rocio_Medio                           8754 non-null   float64
 20  Duracion_Follaje_Mojado               9041 non-null   float64
 21  Velocidad_Viento_200cm_Media          8998 non-null   float64
 22  Direccion_Viento_200cm                9873 non-null   object
 23  Velocidad_Viento_1000cm_Media         8998 non-null   float64
 24  Direccion_Viento_1000cm               9873 non-null   object
 25  Velocidad_Viento_Maxima               9049 non-null   float64
```

```
 26  Presion_Media                        9041 non-null   float64
 27  Radiacion_Global                     9041 non-null   float64
 28  Horas_Frio                           9426 non-null   float64
 29  Unidades_Frio                        9427 non-null   float64
 30  Latitud                              9873 non-null   float64
 31  Longitud                             9873 non-null   float64
 32  Localidad                            9873 non-null   object
dtypes: float64(29), object(4)
memory usage: 2.5+ MB
```

Tipos de variables

Así, podremos ver que el dataset estará compuesto por tipos de datos categóricos (aquellos referidos a la dirección del viento y al nombre de la localidad), geoespaciales (latitud y longitud), temporales (fecha) y numéricos (todos los demás).

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 9873 entries, 0 to 9872
Data columns (total 25 columns):
 #   Column                           Dtype
---  ------                           -----
 0   Fecha                            datetime64[ns]
 1   Temperatura_Abrigo_150cm         float64
 2   Temperatura_Abrigo_150cm_Maxima  float64
 3   Temperatura_Abrigo_150cm_Minima  float64
 4   Temperatura_Suelo_10cm_Media     float64
 5   Precipitacion_Pluviometrica      float64
 6   Precipitacion_Cronologica        float64
 7   Precipitacion_Maxima_30minutos   float64
 8   Tesion_Vapor_Media               float64
 9   Humedad_Media                    float64
 10  Humedad_Media_8_14_20            float64
 11  Rocio_Medio                      float64
 12  Duracion_Follaje_Mojado          float64
 13  Velocidad_Viento_200cm_Media     float64
 14  Direccion_Viento_200cm           object
 15  Velocidad_Viento_1000cm_Media    float64
 16  Direccion_Viento_1000cm          object
 17  Velocidad_Viento_Maxima          float64
 18  Presion_Media                    float64
 19  Radiacion_Global                 float64
 20  Horas_Frio                       float64
```

```
 21  Unidades_Frio                     float64
 22  Latitud                           float64
 23  Longitud                          float64
 24  Localidad                         object
dtypes: datetime64[ns](1), float64(21), object(3)
memory usage: 1.9+ MB
```

Valores faltantes, duplicados e inconsistencias

```
Valores faltantes por columna:
Precipitacion_Maxima_30minutos     1549
Rocio_Medio                        1119
Velocidad_Viento_1000cm_Media       875
Velocidad_Viento_200cm_Media        875
Duracion_Follaje_Mojado             832
Radiacion_Global                    832
Presion_Media                       832
Velocidad_Viento_Maxima             824
Temperatura_Suelo_10cm_Media        757
Precipitacion_Cronologica           744
Precipitacion_Pluviometrica         724
Horas_Frio                          447
Unidades_Frio                       446
Tesion_Vapor_Media                  436
Humedad_Media_8_14_20               398
Temperatura_Abrigo_150cm_Minima     386
Temperatura_Abrigo_150cm_Maxima     380
Humedad_Media                       371
Temperatura_Abrigo_150cm            365
Longitud                              0
Latitud                               0
Fecha                                 0
Direccion_Viento_1000cm               0
Direccion_Viento_200cm                0
Localidad                             0
dtype: int64
```

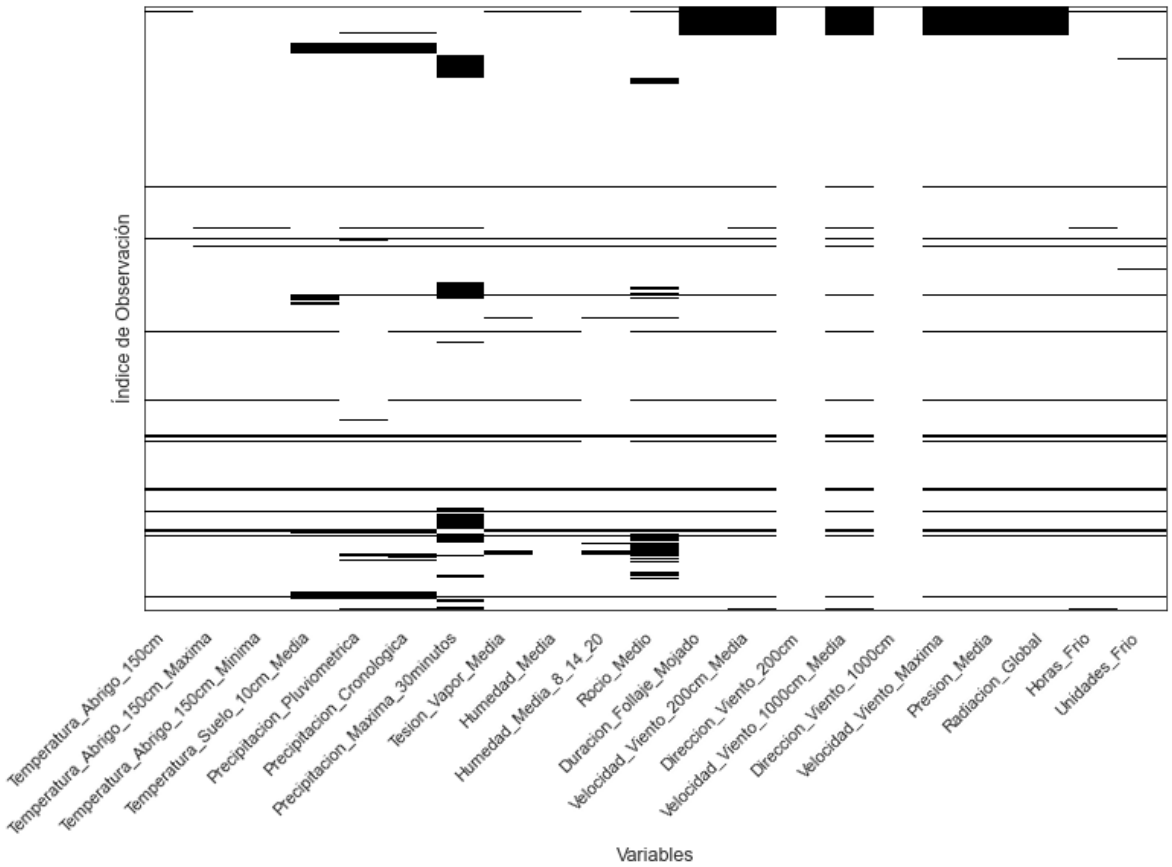

Gráfico 1: Mapa de valores faltantes en el conjunto de datos

Como podemos observar en el mapa, hay múltiples filas en las que se encuentran faltantes en todas las columnas menos en las referidas a la Dirección del viento y la fecha. Por lo tanto, vamos a identificarlas y descartarlas.

Además, puede notarse que la variable objetivo del trabajo, la radiación global, posee una gran cantidad de valores faltantes, principalmente al inicio de los registros del dataset. Teniendo en cuenta que nuestro objetivo será su predicción, deberemos descartar los registros en los que esta variable presente valores nulos.

```
Filas duplicadas:
0
```

Valores atípicos

Por un lado, resulta interesante notar que los valores de la categoría referida a la dirección del viento a 1000 cm son nulos o una 'C'. Ésto es diferente a lo que ocurre en el caso de esta misma medición a 200 cm, que correctamente integra los distintos puntos cardinales. Más allá de suponer que la 'C' significa viento 'calmo' y, considerando que el 97 % de los valores de esa categoría toman el mismo valor, procederemos a dejarla de lado.

```
['C ' 'S ' 'W ' 'E ' 'SE' 'NE' 'N ' 'NW']
['C ']
```

Por otro lado, vamos a utilizar dos métodos gráficos para continuar con la detección de outliers:
- Diagramas de cajas y bigotes - Diagramas de dispersión

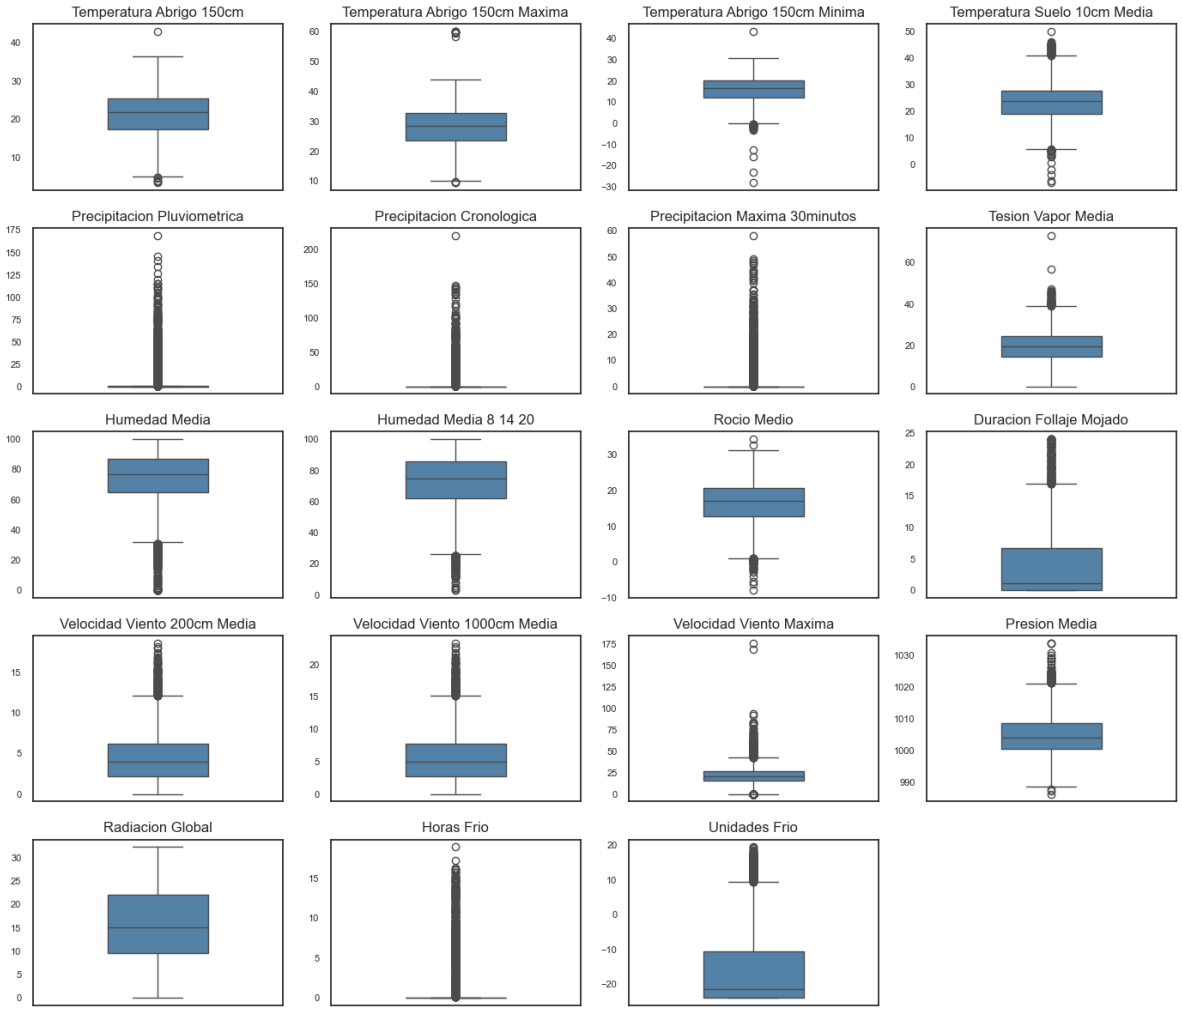

Gráfico 2: Diagramas de cajas y bigotes

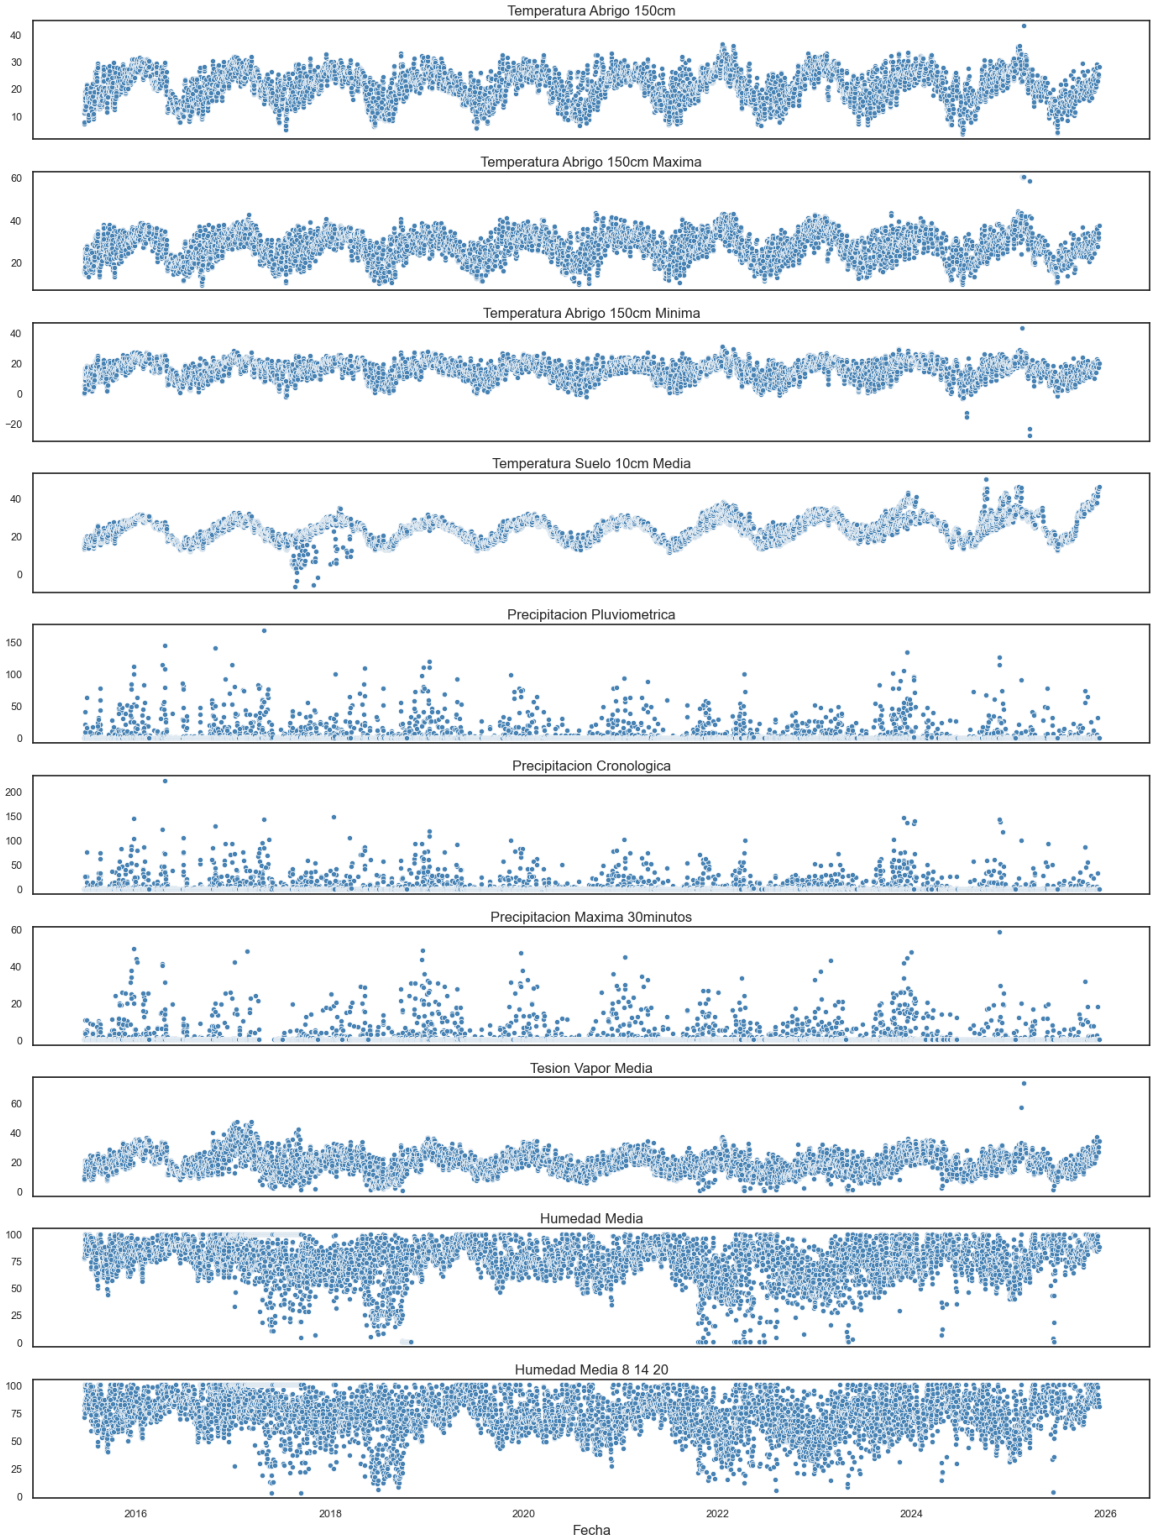

Gráfico 3: Series temporales de las variables estudiadas (I)

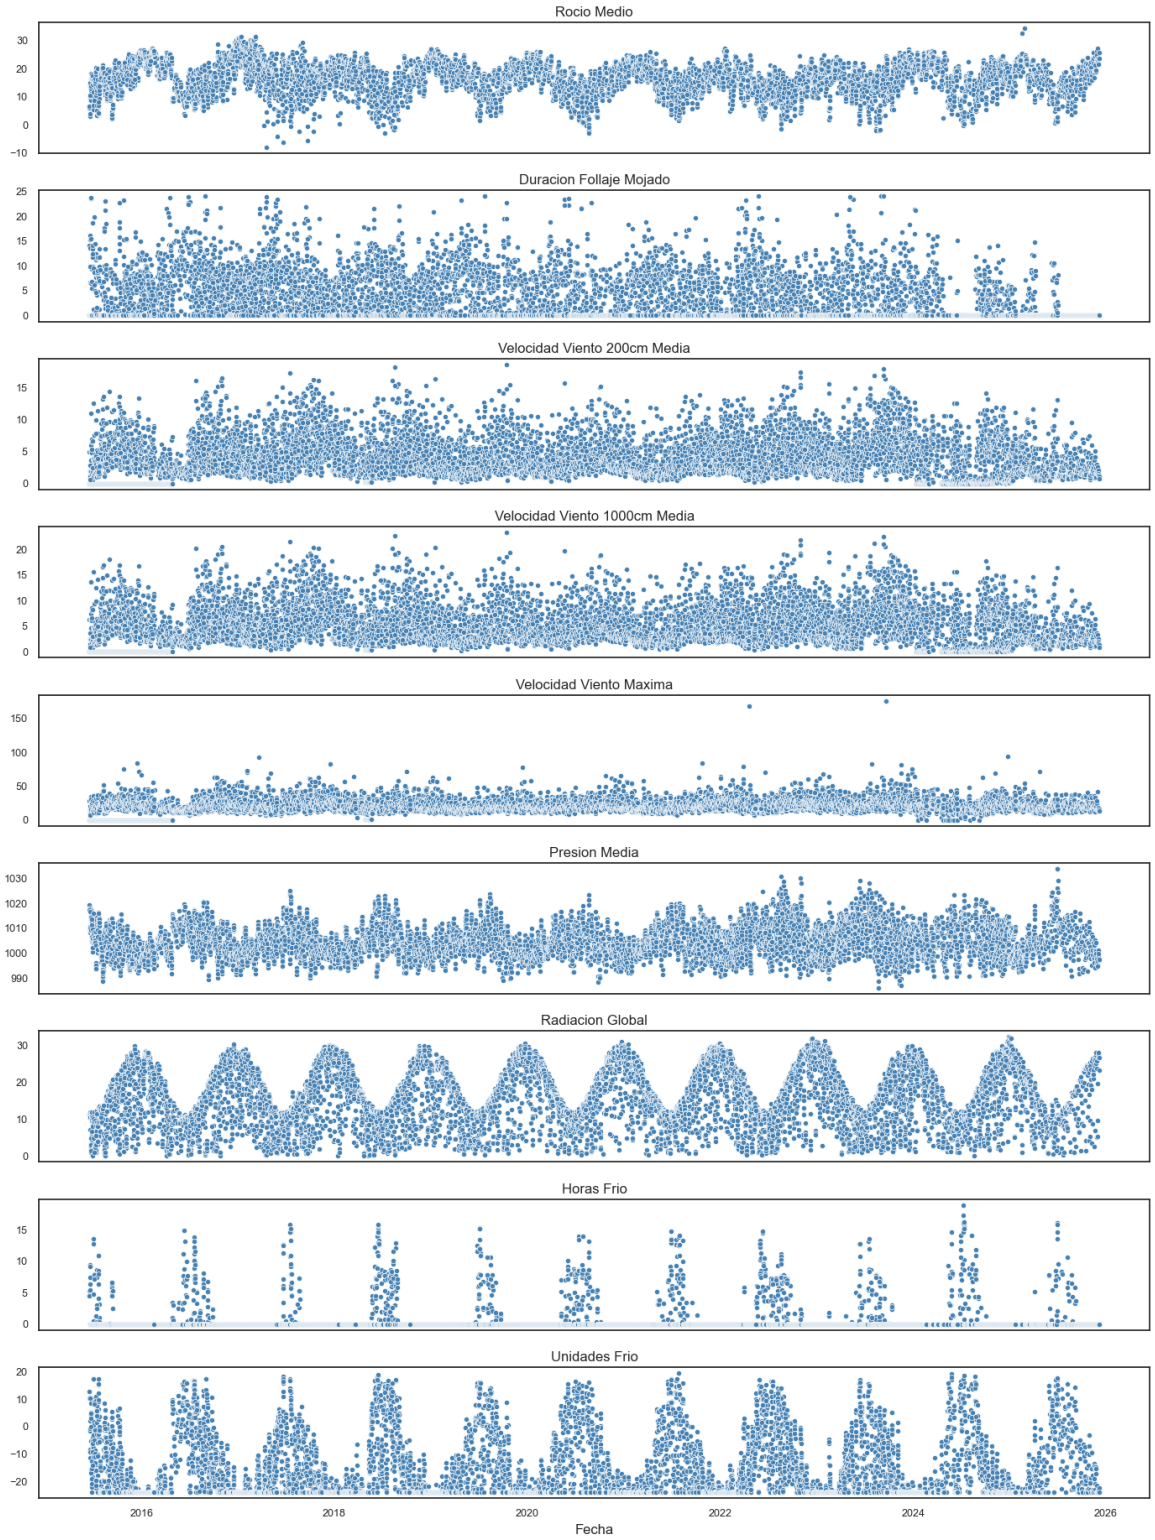

Gráfico 4: Series temporales de las variables estudiadas (II)

En los gráficos de dispersión puede notarse claramente el componente estacional de los datos. Es por ello que vamos a agregar las estaciones del año y los meses como variables categóricas al dataset, ya que podrían ser útiles hacia la predicción de la radiación global.

Resumen estadístico

Variables	min	X25.	X50.	mean	X75.	max	IQR	Moda	std
Temperatura_Abrigo_150cm	3.41	17.32	21.97	21.29	25.57	42.96	8.25	24.91	5.63
Temperatura_Abrigo_150cm_Maxima	9.50	23.60	28.50	27.97	32.70	60.00	9.10	29.70	6.38
Temperatura_Abrigo_150cm_Minima	−28.10	12.10	16.70	15.91	20.30	43.30	8.20	19.80	5.77
Temperatura_Suelo_10cm_Media	−6.80	19.12	23.94	23.70	27.90	50.00	8.78	27.58	5.89
Precipitacion_Pluviometrica	0.00	0.00	0.00	3.16	0.20	169.00	0.20	0.00	11.49
Precipitacion_Cronologica	0.00	0.00	0.00	3.17	0.00	220.00	0.00	0.00	11.94
Precipitacion_Maxima_30minutos	0.00	0.00	0.00	1.25	0.00	58.20	0.00	0.00	4.47
Tesion_Vapor_Media	0.01	14.41	19.22	19.45	24.27	73.20	9.86	11.67	6.90
Humedad_Media	0.00	65.00	77.00	74.63	87.00	100.00	22.00	100.00	17.65
Humedad_Media_8_14_20	3.00	62.00	75.00	73.26	86.00	100.00	24.00	100.00	17.23
Rocio_Medio	−7.96	12.83	17.07	16.49	20.72	34.39	7.89	10.56	5.62
Duracion_Follaje_Mojado	0.00	0.00	1.08	3.57	6.77	24.00	6.77	0.00	4.58
Velocidad_Viento_200cm_Media	0.00	2.22	3.95	4.48	6.19	18.63	3.97	0.00	3.04
Velocidad_Viento_1000cm_Media	0.00	2.78	4.94	5.60	7.74	23.29	4.96	0.00	3.80
Velocidad_Viento_Maxima	0.00	16.10	20.70	22.08	26.80	176.60	10.70	0.00	10.14
Presion_Media	986.28	1,000.38	1,004.11	1,004.73	1,008.71	1,033.71	8.33	1,004.44	6.12
Radiacion_Global	0.02	9.59	15.17	15.51	22.14	32.27	12.55	4.24	7.86
Horas_Frio	0.00	0.00	0.00	0.54	0.00	18.92	0.00	0.00	2.09
Unidades_Frio	−23.90	−23.90	−21.33	−15.87	−10.54	19.51	13.36	−23.90	10.70

Gráfico 5: Resumen de estadísticas descriptivas de las variables.

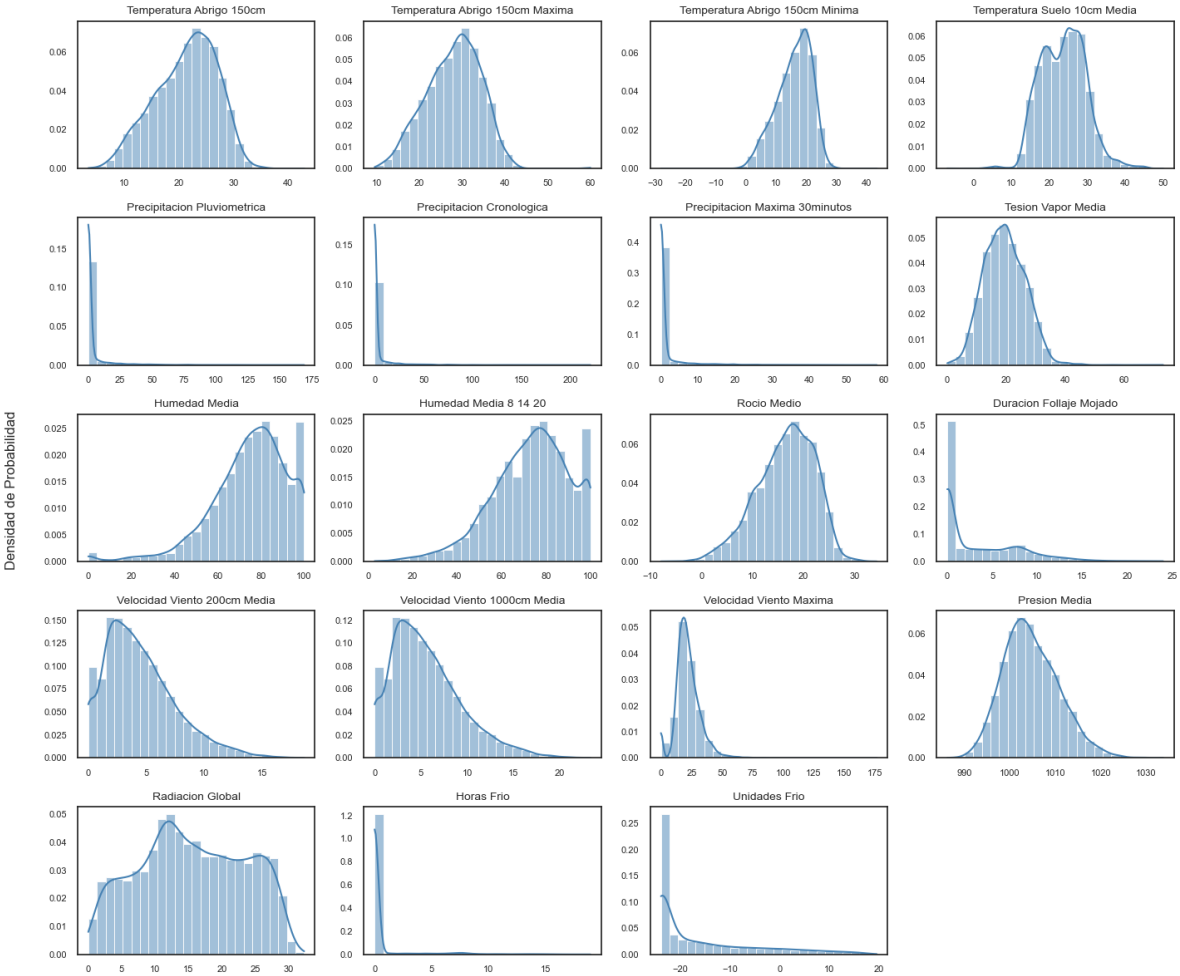

Gráfico 6: Distribución de frecuencias y densidad de probabilidad de las variables

Visualizaciones: análisis bivariado y multivariado

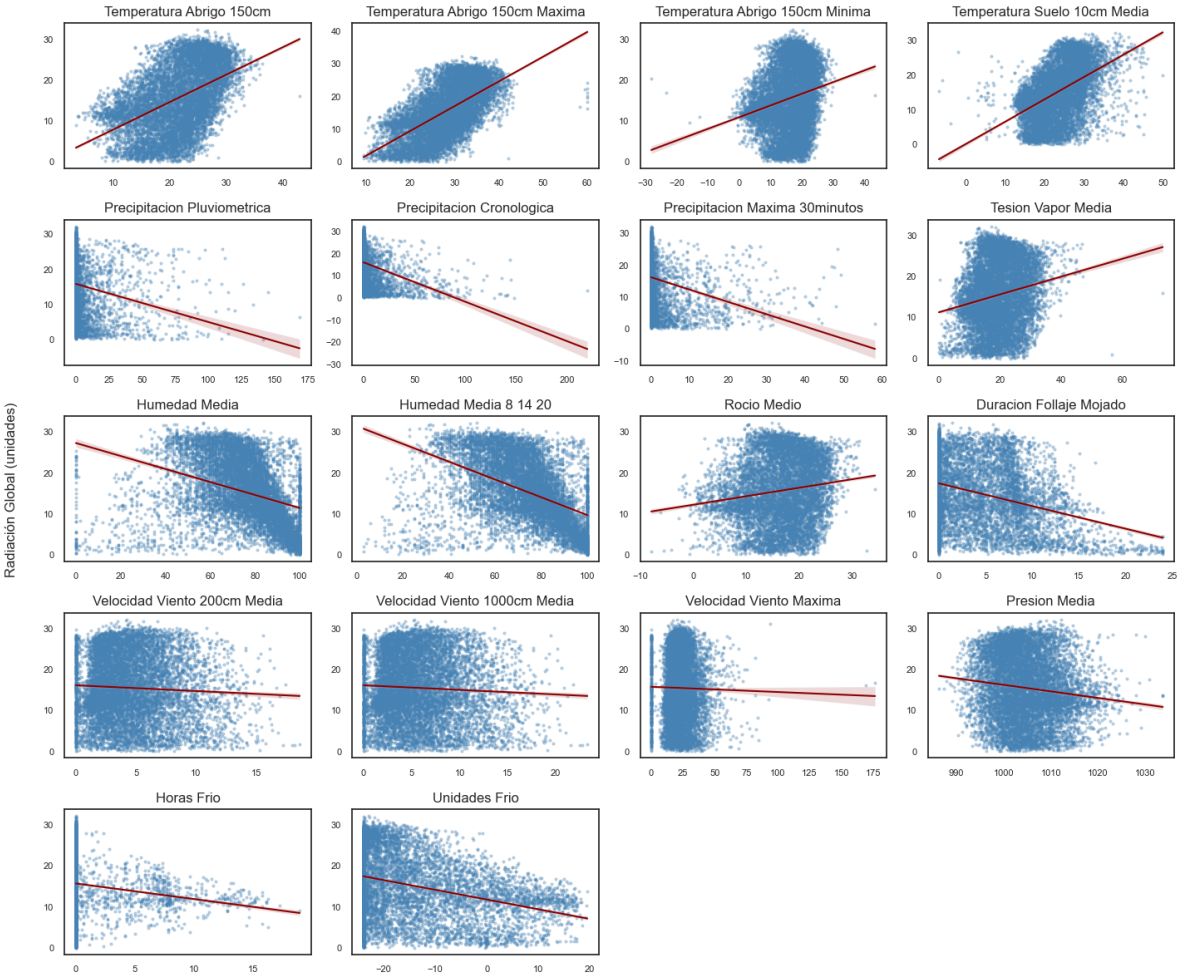

Gráfico 7: Relación entre la radiación global y las variables estudiadas

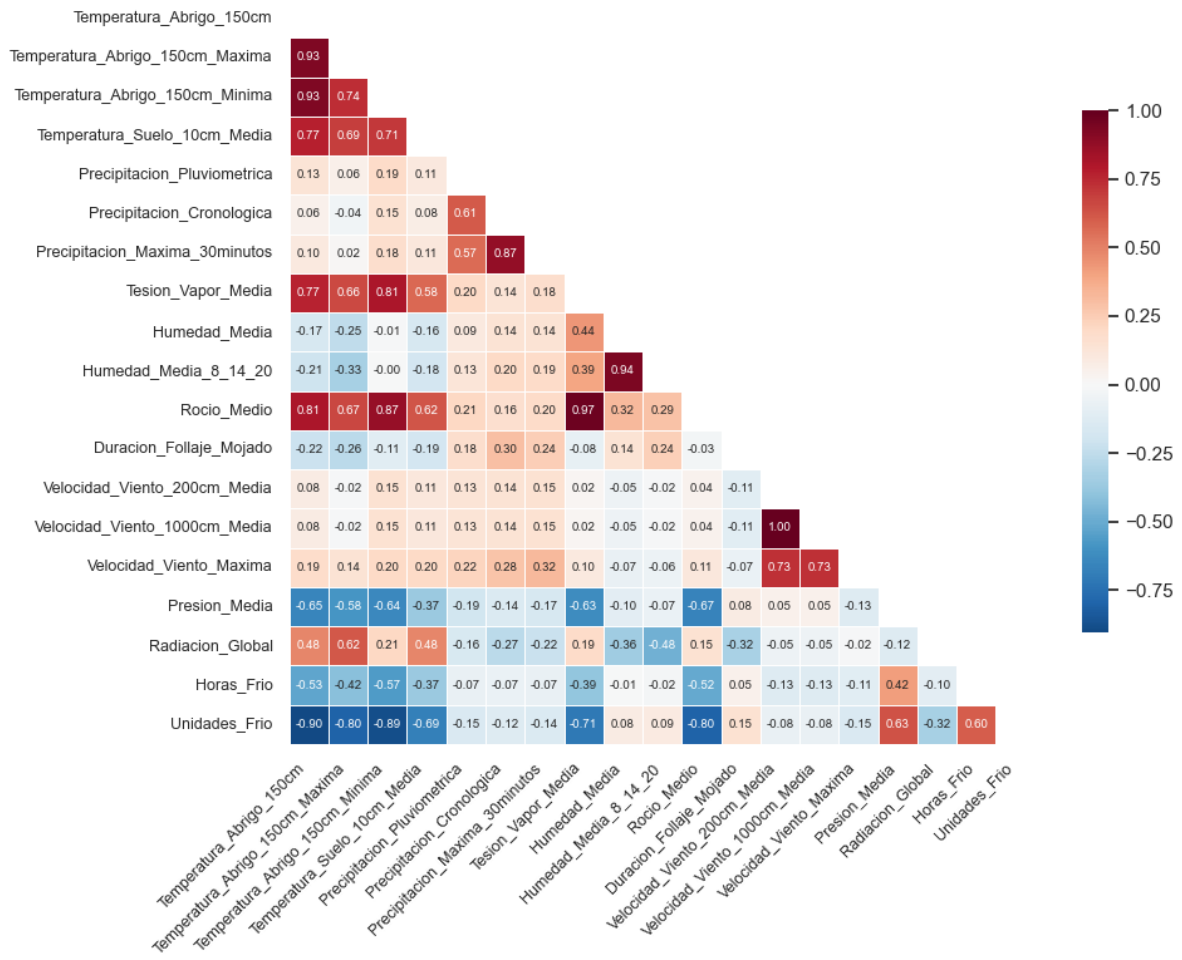

Gráfico 8: Matriz de correlación de Pearson para las variables estudiadas

Preprocesamiento y limpieza avanzada de datos.

Conclusiones parciales

3. Modelado, Evaluación e Interpretabilidad

Selección de modelos

Seleccionar al menos dos algoritmos de machine learning adecuados para el problema planteado y justificar su elección.

Entrenamiento, validación y optimización de modelos

Realizar el entrenamiento de los modelos seleccionados, incorporando técnicas de validación cruzada (cross-validation) y la optimización de hiperparámetros mediante algún método de búsqueda (por ejemplo, Grid Search, Random Search u otros).

Describir el esquema de validación utilizado y los principales hiperparámetros optimizados.

Evaluación y análisis de resultados

Evaluar y comparar el desempeño de los modelos utilizando métricas adecuadas para el problema.

Visualizar y analizar el output de los modelos, incluyendo comparaciones entre valores reales y predichos sobre el conjunto de test.

Detallar y representar gráficamente la "confianza" o incertidumbre asociada a las predicciones, cuando corresponda.

Interpretabilidad de los modelos

Realizar un análisis de interpretabilidad de los modelos entrenados, identificando las variables más relevantes y discutiendo su impacto en las predicciones.

Conclusiones

Elaborar conclusiones integradoras a partir de los resultados obtenidos, destacando fortalezas, limitaciones y posibles mejoras

Referencias

Gentile, E., Martin, P. y Gatti, I. (2020). *Argentina físico-natural: Clima. ANIDA. Atlas Nacional Interactivo de Argentina.* Instituto Geográfico Nacional. https://static.ign.gob.ar/anida/fasciculos/fasc_afn_clima.pdf

Iannone, R., Cheng, J., Schloerke, B., Haughton, S., Hughes, E., Lauer, A., François, R., Seo, J., Brevoort, K., & Roy, O. (2026). *gt: Easily Create Presentation-Ready Display Tables.* https://gt.rstudio.com

Positron. (2024). *Quarto Documentation.* https://quarto.org/docs

Wikipedia, La enciclopedia libre. (s. f.). *Provincia de Corrientes.* Recuperado https://es.wikipedia.org/wiki/Provincia_de_Corrientes